

证券研究报告/ 策略点评报告

FOF 体系 & 多因子体系

--东北证券金融工程 2018 年度策略报告

报告摘要:

2017 年, 我们的工作力求在深度前提下, 继续扩展研究领域, 目前已经构建完善的 FOF 体系, 搭建多因子分析平台, 探索特质波动率、择时因子等新型有效因子, 梳理人工智能历史、算法与投资应用, 从机构交易行为角度研究行业轮动。

FOF 体系: 综述此前研究的包含大类资产配置和基金分析的 FOF 分析体系, 由简入繁、由远及近地提供多种分析思路, 为不同风险偏好和收益目标的 FOF 投资系统提供适宜的解决方案。

多因子体系: 多因子分析由点及面, 实现组合构建, 涵盖单因子测试和特征分析、因子筛选。**单因子测试和特征分析**结果显示, 国内质量因子表现出防御特征, 市值、动量、低波因子分别表现出顺周期、全周期和防御特性。**因子筛选**是在基准模型的因子基础上添加某个新的因子带来的截距项变化, 来确定该因子是否提供了额外的信息。经过多因子打分筛选出来的股票组合, 也表现出更稳定的特征。

特质波动率及择时因子: 基于因子筛选研究个股特质波动率, 据此构建的 STDO 和 STDN 因子有较强的有效性, 组合年化收益率分别为 25.80% 和 27.50%, Sharpe 比分别为 0.711 和 0.760。**择时因子**, 在时间序列维度上分析构建因子, 结果显示 EP_Q_3Y 在全 A 和中证 500 的选股能力较强, EP_Q_5Y 在全 A、沪深 300 和中证 500 的选股能力均较强, EP_Q_3Y 与 EP_TTM 自身有较强的相关性, 与反转因子相关性不高。

其他研究: **风格轮动**, 以 Fama-French 三因子模型为出发点, 对当前因子收益水平下对应的下一个周期风格以逻辑关系进行风格轮动的探究。**人工智能研究**, 围绕人工智能的发展历史, 主要算法以及金融投资领域应用进行梳理, 力求为投资者勾勒出一幅人工智能全景图。**机构交易行为视角下的行业轮动**, 利用股票超大单资金数据研究机构交易行为中的行业偏好, 结果显示机构投资者主动净买入指标具有较强有效性, 构建的行业轮动组合相对基准有显著的超额收益。

展望: 建立完备的多因子选股体系, 为市场的最重点需求提供服务和思路; 深耕人工智能投资策略研究、开拓行为金融领域探索, 为新的因子开发开辟新大陆。

相关报告

- 《大类资产配置(2): 应用极值理论和 Copula 实现动态资产配置》
2017-02-02
- 《大类资产配置(3): 超越“风险”平价》
2017-02-27
- 《东北金工: 风格轮动初探》
2017-03-18
- 《FOF: 债券型基金业绩归因》
2017-05-16
- 《大类资产配置(4): 多资产多因子策略》
2017-06-05
- 《多因子系列(1)-单因子测试和特征分析》
2017-08-25
- 《多因子系列(2)-因子筛选》
2017-09-09
- 《东北证券人工智能系列报告综述篇:
人工智能发展史及算法介绍》
2017-10-11
- 《基于因子筛选的特质波动率研究》
2017-10-25

证券分析师: 高建

执业证书编号: S0550511020011

研究助理: 王琦

执业证书编号: S0550116060053

021-20363215 wang_qi@nesc.cn

研究助理: 肖承志

执业证书编号: S0550116080014

021-20361264 xiaocz@nesc.cn

研究助理: 孙凯歌

执业证书编号: S0550117100006

021-20363217 sunkg@nesc.cn

目录

1. FOF 体系	3
1.1. 大类资产配置.....	3
1.1.1. 静态优化模型.....	3
1.1.2. 动态预期模型.....	4
1.1.3. 多资产多因子配置策略.....	5
1.2. 基金分析.....	6
1.2.1. 股票型基金持仓分析.....	6
1.2.2. 股票型基金基于净值分析和指数拟合优度匹配.....	7
1.2.3. 债券型基金分析.....	8
2. 多因子体系	8
2.1. 单因子测试和特征分析.....	8
2.1.1. 单因子计算.....	8
2.1.2. 质量因子.....	10
2.1.3. 价值因子.....	12
2.1.4. 市值、动量、波动率和流动性因子定义.....	14
2.2. 因子筛选.....	17
2.2.1. 模型说明.....	17
2.2.2. 检验过程.....	18
2.2.3. 结果展示.....	18
2.3. 特质波动率.....	19
2.3.1. 研究逻辑.....	19
2.3.2. 回测检验.....	21
2.4. 新因子探索——择时因子.....	23
2.4.1. 择时因子的由来.....	23
2.4.2. 分位数择时因子回测结果.....	25
2.4.3. EP 分位数因子与 EP 因子和反转因子的相关性.....	31
3. 其他研究	33
3.1. 风格轮动.....	33
3.1.1. 理论介绍.....	33
3.1.2. 建模方法和结果.....	33
3.2. 人工智能.....	34
3.2.1. 人工智能发展历史.....	35
3.2.2. 人工智能算法.....	36
3.2.3. 人工智能在金融投资领域应用.....	38
3.3. 机构交易行为视角下的行业轮动.....	39
3.3.1. 理论基础.....	39
3.3.2. 策略构建和结果.....	40
4. 总结和展望	44

1. FOF 体系

本节将综述此前研究的包含大类资产配置和基金分析的 FOF 分析体系，由简入繁、由远及近地提供多种分析思路，为不同风险偏好和收益目标的 FOF 投资系统提供适宜的解决方案。

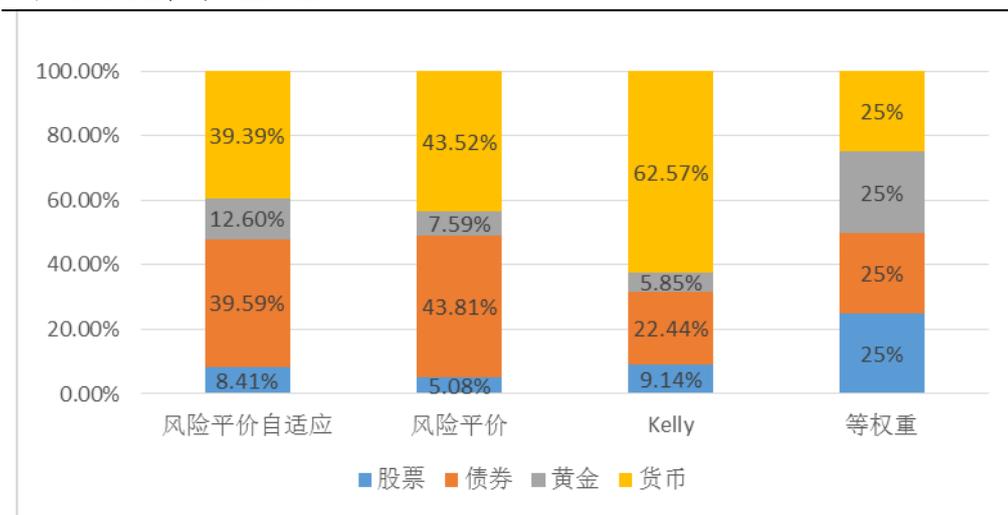
1.1. 大类资产配置

1.1.1. 静态优化模型

静态优化模型即为常见的包含均值方差、风险平价、尾风险平价、目标波动、最大多元化等优化方法的模型。在我们大类资产配置系列报告的《FOF：从大类资产配置到股票型基金的选取》以及大类资产配置 1、2&4，均是围绕静态优化模型进行介绍和回溯的。

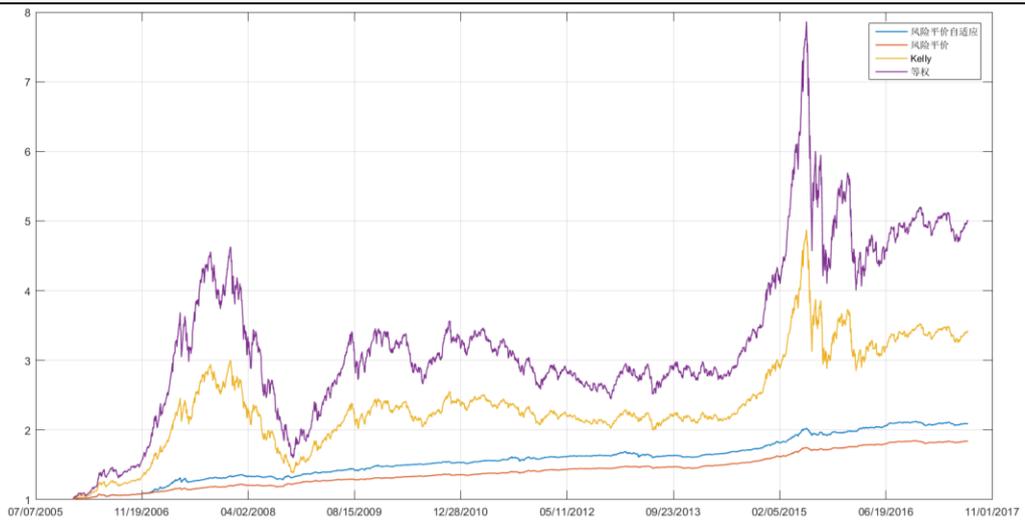
方法之一是通过通过对风险平价和凯莉公式的资产配置模型与考夫曼自适应均线的思路结合，使得每个调仓周期根据当前市场波动状态判断参数回溯窗口长度，进而确定协方差等参数的计算。从图 1 和图 2 的结果上可以看出动态调整参数估计窗口长度的方法比原始方法减少低波资产的配置权重，进而实现了收益增强。

图 1：历史平均配置权重



数据来源：东北证券，Wind

图 2: 历史净值



数据来源: 东北证券, Wind

方法之二是尾风险的分析, 包括在保持各类资产时间序列和截面相关性基础上模拟不同程度的尾风险和收益的平衡关系, 以及 VaR/ES 平价模型。而由于历史方法估计的尾风险变化极为缓慢, 对于历史形态过度依赖, 使得对于现实变化较为迟钝, 与此同时, 提高了风险指标的平价模型更进一步的提高了低波资产的配置比例, 使得在债券投资回报率降低的近期无法实现客观的收益。因此我们又进行了新的资产配置模型探索。

1.1.2. 动态预期模型

优化模型的资产配置方法依赖历史数据的片段, 且对参数较为敏感, 可以发现变更资产类别以及参数估计窗口都会对模型回测结果带来较大的变化, 因此使用上应结合宏观判断。另一方面, 我们认识到, 在长期风险度量上, 各类资产的多元正态的概率分布假设较强, 而实际中各类资产的分布多呈现尖峰肥尾的特点。因此, 我们期望使用跟贴近现实的模型做风险拟合以及资产配置。

投资分散化并不能足够有效预防极端风险中的重大损失, 对市场风险的动态判断并动态调整资产配置比例能够降低风险冲击同时保持获利的可能性。方法上, 一方面通过极值理论 (Extreme Value Theory) 重新拟合各类资产的尾部分布特征, 同时应用 t-Copula 更好的捕捉各类资产的相关性, 尤其是在极端风险中各类大类资产趋向同时“变坏”的相关性。通过模拟未来资产收益率分布的可能性, 计算不同配置比例下 CVaR 变化情况。最后对比了不同目标 CVaR 下最大化预期收益的配置比例的净值回测结果, 同时提出了可以根据当前 CVaR 在历史 CVaR 的分位情况调整目标 CVaR, 控制可能出现极端风险时的几类资产的配置比例, 从而实现更具前瞻性的风险控制。

具体建模方法, 参见《大类资产配置 3: 应用极值理论和 Copula 实现动态资产配置》。

动态配置模型通过收益率左右尾部分布的形态变化, 判断市场风险程度, 通过 CVaR 表现高阶矩偏离常态的程度, 实现大的风险来临前的及时防控, 不仅对股票等风险资产有一定的风险控制能力, 对于债券等低波资产发生黑天鹅的情况同样能够较为

有效的预防。具体结果见图 3。

图 3: 7%-12%配置净值和配置比例变化图



数据来源：东北证券，Wind

1.1.3. 多资产多因子配置策略

在《大类资产配置 5: 多资产多因子策略》中，我们通过增加大类资产的分析维度，借鉴每个单类资产的多因子分析法，将每类资产从“价值、动量、利差和波动”四个角度进行评价，根据每类资产的每个因子在时间序列上的排序情况进行打分，而后对四个因子等权计算该类资产的总平均分，根据得分确定权重。长期来看，单因子指数虽然能够显示出较显著的风险调整后的收益，而短期来看，单一因子可能存在较大的回撤和波动。因此我们寻求从多因子角度对各类资产进行打分配置权重，丰富评价维度并进行风格分散。相似的方法在 MSCI 和 AQR 等机构均有所应用。

FOF 基金的核心优势在其资产配置能力。一方面，宏观经济周期影响着不同资产的相对表现，很难有一类资产可以穿越历史。通过多资产合理配置，可以抵御不同经济周期下单一资产的风险。另一方面，历史表现证明了，简单且分散的组合配合优异的资产选择能够在实践中超越诸多基于收益率和波动率的优化模型的结果。因此我们希望通过多维度资产分析并结合简单但充分的配置方案获得稳定的表现。

表 1: 数据摘要及因子定义

	股票	债券	黄金
数据名称	万得全 A	中证国债	黄金 9999、黄金期货
回溯时间	2007.01—2017.05	2007.01—2017.05	2007.01—2017.05
价值	BP	10 年实际收益率	过去 3 年平均价格与当前价格比
动量	过去 6 个月涨跌幅	过去 6 个月涨跌幅	过去 6 个月涨跌幅
利差	过去 12 个月平均每股现金分红	1 年、5 年期限溢价	期限结构
波动率	过去 6 个月波动率	过去 6 个月波动率	过去 6 个月波动率

数据来源：东北证券，Wind

结果展示，多资产多因子配置方案较为稳健，不会过度偏移任何一类资产或风格，且无论单纯考察风险还是评价收益风险比，均比等权和 60/40 方案有较大提高。

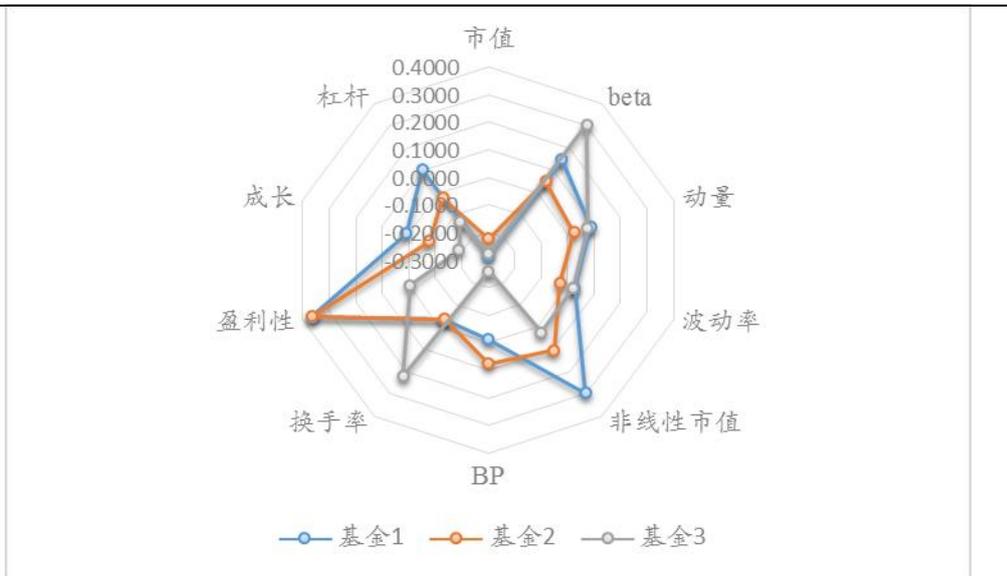
1.2. 基金分析

1.2.1. 股票型基金持仓分析

基于持仓的分析近来受到较多的关注，通过对持仓个股和权重的归类，将持仓映射到风格以及行业配置上，分析收益和风险来源。

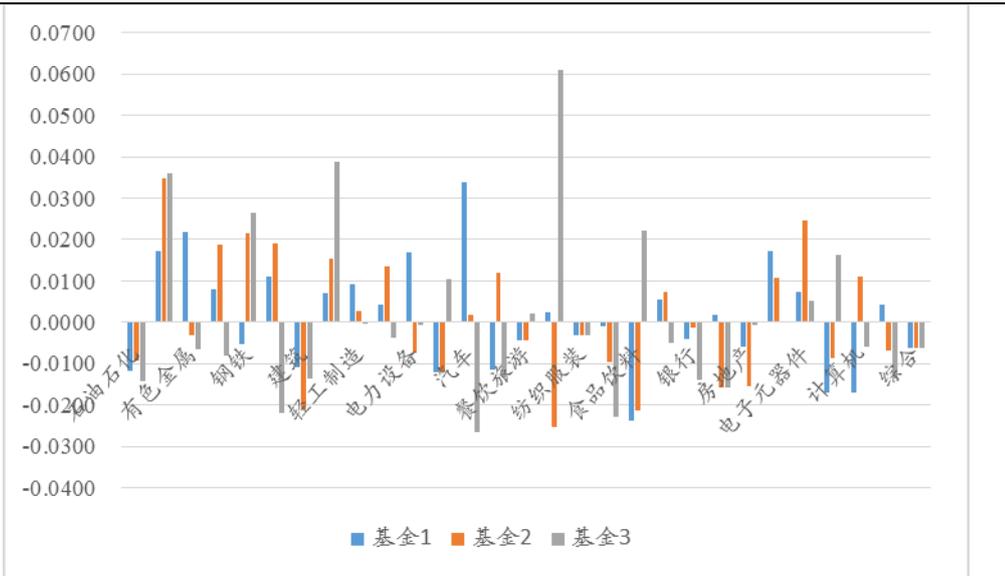
图 4 和图 5 展示了 2017 年半年报披露的三只收益十分可观的沪深 300 指数增强基金的持仓分析。可以看到，即使这三只基金今年收益较高，但超额收益的来源并不尽相同，其中基金 1 和基金 2 的风格配置和基准沪深 300 较接近，超额暴露较平衡，仅在盈利性上有较高的正暴露，市值上略低于沪深 300。而基金 3 则于谦两只略有不同，风格偏好上相比沪深 300 更偏好高估值和低成长。行业上，三只基金则各有偏好。可以看出，即使业绩均领跑同类型其他基金，但收益来源却不尽相同，能够提供业绩以外的关于各基金的更多信息。

图 4: 相对沪深 300 的风格超额暴露归因



数据来源：东北证券，Wind

图 5: 相对沪深 300 的行业超额暴露归因

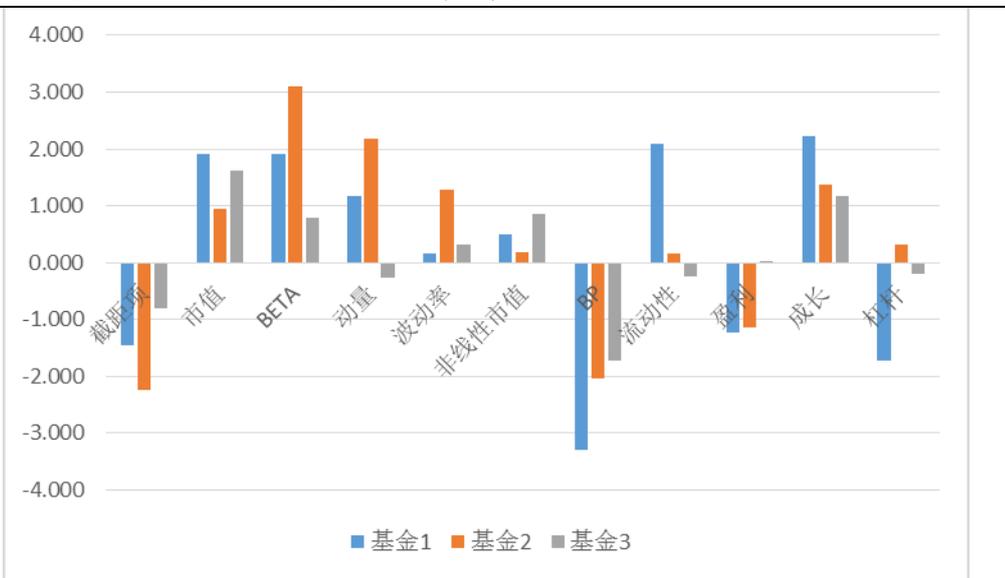


数据来源: 东北证券, Wind

1.2.2. 股票型基金基于净值分析和指数拟合优度匹配

受制于持仓披露的不及时以及频率有限, 基于持仓的分析常常无法满足基金风格分析的需求, 因而延伸出基于净值(收益)的分析, 即类似于 Fama-French3 因子回归方程, 解释变量扩充为 Barra 十因子时间序列收益序列, 被解释变量基金同时段收益率序列, 通过简单回归计算该基金收益对于每个风格因子的斜率。

图 6: 基于收益的分析各变量显著性(t 值)对比



数据来源: 东北证券, Wind

该方法可以解决由于持仓信息匮乏带来的不便, 但由于估计数据较多, 存在较大的误差, 对于部分风格不显著和回归系数漂移较大等问题也没有很好的解决方案。我们认为可以尝试对每个基金进行单独分析, 保留解释有度最高且显著解释收益的风格变量, 来判断该基金的风格偏好。这与使用单一指数的收益对基金收益进行回归选择拟合优度最高的指数作为该基金的参考指数思路相似, 均可以提供一部分

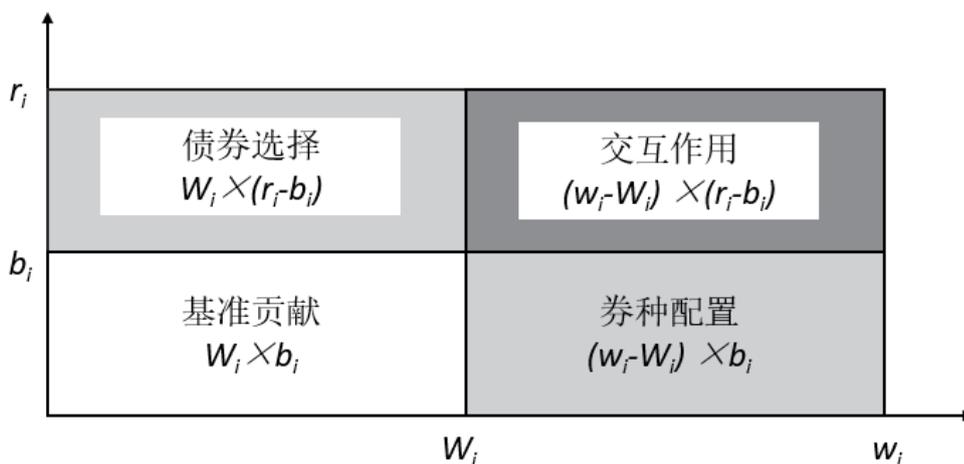
该基金风格偏好的信息。

1.2.3. 债券型基金分析

无论是股票型基金还是债券型基金，在持仓信息不完整的情况下，都无法确切地了解其配置偏好和策略风格，这使得对子基金的分析在很多时候都显得捉襟见肘。然而我们认为，除了传统的 Sharpe、Stutzer、最大回撤等简单业绩评价指标，从每个季度配置情况来分析，也可以从时间积累上分析出基金经理的择时和选股/券能力，为子基金的选择提供更有价值的信息。其中较为著名且可以用来做债券基金分析的方法之一就是 Brinson(BHB 19986/Brinson and Fachler/ Davies & Laker 2001)系列方法。

BHB 模型对超额收益部份 (r-b) 分解为券种配置收益、债券选择收益和交互作用收益。

图 7: Brinson 收益分解



数据来源：东北证券，Wind

我们针对券种配置部分的计算，跟踪了全市场全部中长期纯债的配置能力结果，可以发现优异的券种配置能力与历史业绩的平稳和杠杆使用的节奏相吻合，可以在基于历史收益的简单指标之外，提供更多的信息。

本文可参考《FOF：债券型基金业绩归因》。

2. 多因子体系

2.1. 单因子测试和特征分析

我们的样本空间为上市满 1 年的非停牌全部 A 股，计算区间为 2006 年 3 月至 2017 年 6 月，每月末计算截面单因子数据，并分别根据单因子截面回归和分组 rank IC 总结每个因子的收益预测能力。

2.1.1. 单因子计算

Step1. 规范化处理

我们参照 Barra 计算单因子的方法，使用以下方法计算截面标准化、去极值结果

$$X_{nk}^{(std)} = \frac{X_{nk}^{(raw)} - \mu_k^{cap}}{\sigma_k} \quad (2.1)$$

$$\tilde{X}_{nk}^{(std)} = \begin{cases} 3 \cdot (1 - s_{(+)}) + X_{nk}^{(std)} \cdot s_{(+)} & ; X_{nk}^{(std)} > 3 \\ X_{nk}^{(std)} & ; -3 \leq X_{nk}^{(std)} \leq 3 \\ -3 \cdot (1 - s_{(-)}) + X_{nk}^{(std)} \cdot s_{(-)} & ; X_{nk}^{(std)} < -3 \end{cases} \quad (2.2)$$

$$s_{(+)} = \max \left\{ 0, \min \left\{ 1, \frac{0.5}{\max(X_{nk}^{(std)}) - 3} \right\} \right\} \quad (2.3)$$

以上标准化方法，即原始数据减市值加权平均，除以简单平均波动率，使得标准化因子市值加权的组合是风格中性的。去极值的方法一方面将偏离值拉回到[-3.5,3.5]范围内，并且能够使得大于3个标准差的数值在3至3.5之间保留了原始的秩序：数值为4的股票数据一定比数值为20的股票数据缩放的数值小。

经过以上两步计算之后，我们再次对去极值后的数据进行标准化，以保持市场组合中性的特征。

Step2. 市值和行业正交

财报和估值因子常常受到行业特性和市值影响，呈现出某些行业整体数值过高或过低。为了消除这种影响，使得筛选的股票具有可比性，我们需要对财务数据和估值数据对行业和市值进行正交。我们的做法是以对数市值(ln(Cap))和中信一级行业哑变量为解释变量，标准化后的指标数据作为被解释变量，进行多元线性回归，取残差作为正交后因子数值，并再次进行市值平均标准化(2.1)。

而对于基于交易的数据，例如涨跌幅、换手率等，受到市值影响更明显，因此对于这一类数据，我们对其进行了市值正交，取回归残差作为因子数值。

Step3. 单因子有效性检验

因子有效的评价标准是其是否对股票未来收益具有持续的预测能力。常用的计算方法有回归法和排序法。

在回归法中，解释变量为当前截面标准化后的因子数据，被解释变量为下一周期的股票收益，通过回归系数的显著性和显著方向来判断因子的有效性。形式如下

$$\bar{R}_{t+1} = a + b\bar{X}_t + e_{t+1} \quad (2.4)$$

其中， \bar{X}_t 为t期期末的因子序列， \bar{R}_{t+1} 为t至t+1的周期内的股票收益，b为待求系数，即为因子收益，其显著性和显著方向是我们的关注重点。

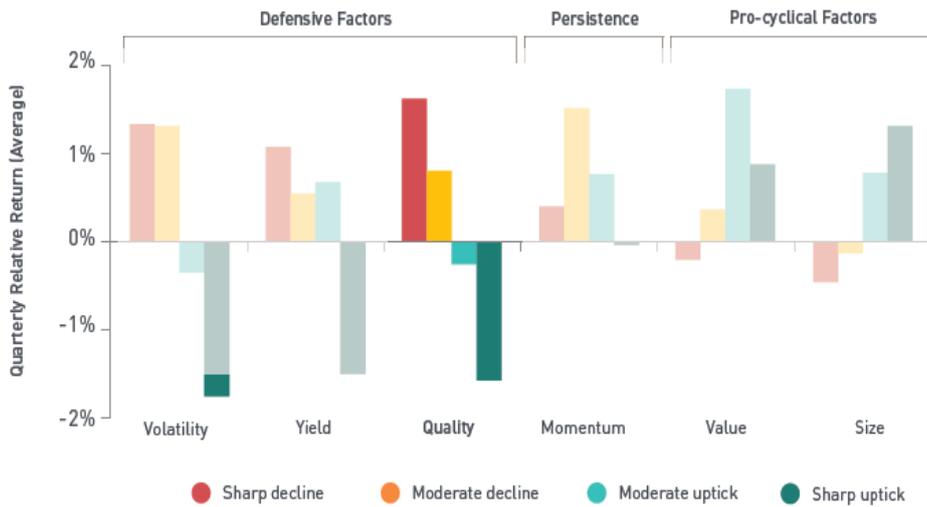
在排序法中，理论上使用t期的因子收益和t+1期的股票收益的相关系数计算因子IC。但实际操作中，通常将因子数值由小到大分为若干组，并记录每组在t至t+1内的组合收益排序，最后计算秩相关系数作为当期的因子IC。通过计算一段时间的IC均值和t值(H0: IC均值=0)和分组组合的净值分散度等指标，判断该因子的有效性。

本文对所有因子都进行了以上两种方法的有效性检验，并以 rank IC 显著不为 0 作为因子选择标准，选出了以下章节中的因子。虽然截面回归的方法可以得到每一期的因子收益估计和显著性等指标，但由于单因子截面解释能力(R²)非常低 (<5%)，按照这种方法计算的因子 t 值会对于因子筛选过于严苛。此外，我们在 Barra 系列报告中也曾说明，截面回归的残差收益率的波动率与市值平方根的倒数有一定的相关性，因此需要进行加权回归等操作。因此，我们最终将 rank IC 作为筛选因子的标准。

具体的，在每个截面将因子数值从小到大排序分为五组，依次记为 G1-G5，并记录各组在下一个周期的收益表现，最后统计净值结果和各组超额收益情况。具有较强的收益预测能力的因子特征一方面表现为 IC 显著不为 0 (t 值绝对值大于 2)，同时分组净值区分度高，并且超额收益较稳定。**如果因子大小与股票预测收益大小正相关，则组别序号越大收益越高**，否则反之。因此在以下的展示中可以看到，如果因子是正向因子，序号越大的组其超额收益越高。

图 8 为 MSCI 不同风格指数(波动率、红利、质量、动量、价值、市值)在不同市场环境(迅速下跌、缓慢下跌、缓慢上涨、迅速上涨，1975/11/28--2016/09/30)中的季度平均收益统计。不同风格有较明显的收益特征差异，在不同市场环境中表现出现分化，适应的市场环境不同。我们参照这种区分方法，把所有覆盖的因子分为质量、价值、市值、动量、波动率等类别，并且将回溯区间分为牛、熊、震荡三种市场行情，分别计算因子在每一段时间上的显著性和收益情况，以检验国内各大类因子是否具有相似特征。

图 8: MSCI 风格指数历史季度平均收益表现



数据来源：东北证券，MSCI

2.1.2. 质量因子

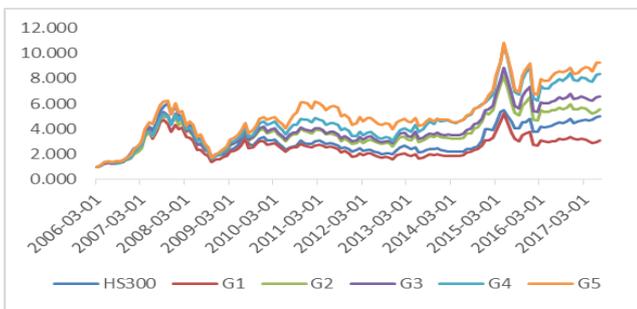
量因子在学术上指那些能够捕捉公司稳健经营能力和竞争能力的因子。国外的长期跟踪经验显示，**质量因子是一类防御因子**，即这类风格能够在市场处于下跌阶段保持获益。研究这类风格同时有助于解释了具有低杠杆、稳定收益和高盈利性股票的收益特征。

MSCI 的质量风格指数使用了 3 个基础风格变量：净资产收益率(ROE)，显示了上市公司盈利能力；权益比率(Debt to equity)，显示了公司的杠杆使用情况；收益变动率(Earnings variability)，显示了收益增长的稳定性。以此构建的质量风格指数在 1999 年至 2016 年间的表现也较为优异，尤其是在 2007/2008/2013/2014 等年间，与其他风格指数相比，年化收益排名较高，全区间（年化）收益风险比约为 0.82。

当然，质量因子的选择不局限于 MSCI 的三个因子，我们对大量的质量因子进行了计算和统计，将显著有效的因子的表现及其在不同市场环境（牛市、熊市、震荡市）中的表现都进行了统计。回溯结果表明，质量因子在震荡和熊市行情中的超额收益通常为正值，而牛市中则无法超越基准。这也显示了，国内市场的质量因子也具有防御因子特征。

质量因子结果示例：

图 9：净资产收益率 ROE(平均)分组净值



数据来源：东北证券，Wind

表 2(1)：ROE(平均)全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	16.27%	-3.77%	35.24%	-70.41%
2	21.02%	0.99%	33.89%	-64.95%
3	22.48%	2.44%	33.60%	-68.92%
4	25.03%	4.99%	35.08%	-68.74%
5	25.95%	5.92%	34.88%	-71.88%

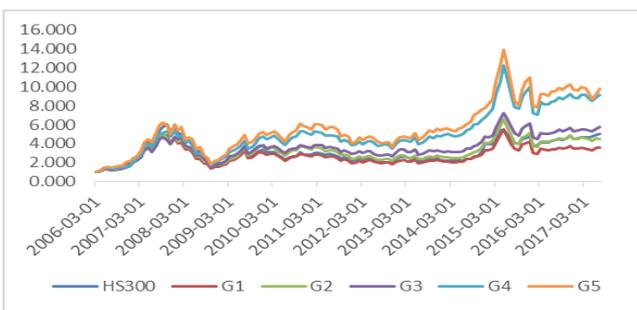
数据来源：东北证券，Wind

表 2(2)：ROE(平均)不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	110.65%	-13.77%	33.86%	12.33%	0.86%	26.66%	-90.16%	-11.69%	42.81%
2	111.71%	-12.71%	32.91%	16.93%	5.46%	25.50%	-79.74%	-1.27%	41.56%
3	111.93%	-12.50%	30.07%	19.36%	7.89%	24.87%	-79.48%	-1.00%	44.42%
4	108.92%	-15.50%	32.41%	24.49%	13.02%	26.53%	-79.84%	-1.37%	46.45%
5	119.59%	-4.84%	29.84%	23.69%	12.21%	24.89%	-83.73%	-5.26%	48.43%

数据来源：东北证券，Wind

图 10：利润总额(同比增长率)分组净值



数据来源：东北证券，Wind

表 3(1)：利润总额(同比增长率)全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	17.63%	-2.40%	35.46%	-71.90%
2	19.49%	-0.55%	34.84%	-69.07%
3	20.93%	0.90%	32.86%	-66.27%
4	25.51%	5.47%	33.99%	-66.71%
5	27.15%	7.11%	36.98%	-70.11%

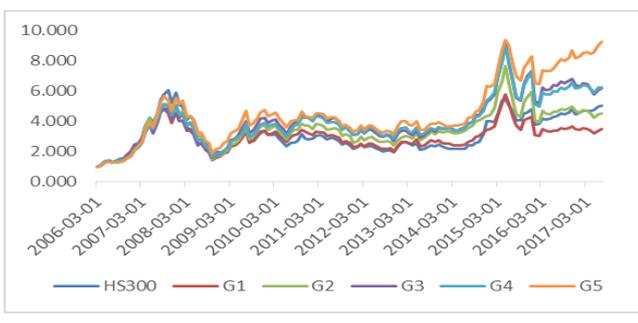
数据来源：东北证券，Wind

表 3(2): 利润总额(同比增长率)不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	111.91%	-12.51%	31.91%	15.09%	3.62%	26.78%	-92.18%	-13.71%	44.95%
2	108.99%	-15.43%	32.02%	16.32%	4.85%	26.16%	-81.16%	-2.69%	46.06%
3	104.28%	-20.14%	33.21%	17.73%	6.25%	24.09%	-73.67%	4.81%	42.30%
4	115.55%	-8.87%	32.51%	23.21%	11.74%	24.71%	-81.14%	-2.66%	43.45%
5	119.47%	-4.95%	33.84%	24.16%	12.69%	27.03%	-81.08%	-2.60%	51.05%

数据来源: 东北证券, Wind

图 11: 股息率(近 12 个月)分组净值



数据来源: 东北证券, Wind

表 4(1): 股息率(近 12 个月)全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	17.43%	-2.61%	35.48%	-70.85%
2	20.07%	0.03%	36.31%	-70.31%
3	22.20%	2.17%	34.54%	-67.39%
4	22.06%	2.03%	33.84%	-68.00%
5	25.34%	5.30%	33.32%	-66.22%

数据来源: 东北证券, Wind

表 4(2): 股息率(近 12 个月)不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	105.57%	-18.85%	36.64%	15.21%	3.74%	25.44%	-87.67%	-9.20%	46.10%
2	108.27%	-16.15%	32.84%	18.94%	7.47%	26.82%	-88.27%	-9.79%	50.02%
3	112.23%	-12.20%	28.97%	19.88%	8.41%	26.86%	-83.79%	-5.31%	44.32%
4	113.30%	-11.13%	26.91%	19.75%	8.28%	25.90%	-84.43%	-5.95%	44.39%
5	115.92%	-8.50%	33.20%	19.81%	8.34%	24.40%	-68.68%	9.79%	42.32%

数据来源: 东北证券, Wind

2.1.3. 价值因子

价值投资俨然已经成为过去几十年中主动管理最成功的投资方法之一。价值投资的内涵是投资那些当前相对于内在价值被低估的股票, 这些股票在历史收益情况来看, 能够在长期投资中提供超越其他“更贵”的股票的收益。价值风格可以从很多维度分析: 市价收益比、价格分红比、市值账面价值比, 以及其他类似的“比率”。价值因子是顺周期因子。

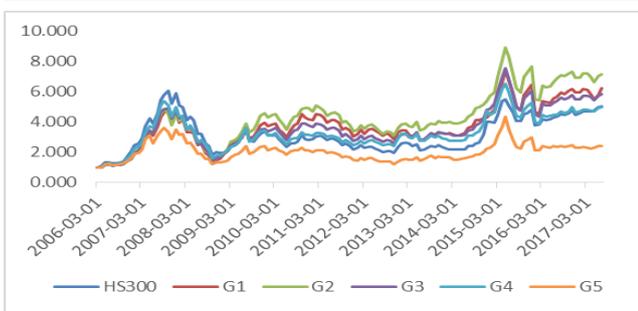
MSCI 的价值风格指数使用了 3 个基础风格因子: 预期市盈率(Fwd P/E)、企业价值和营运现金流比(EV/CFO), 以及市净率(P/B)。对于以上三个基础因子的选择, MSCI 给出了以下解释: “这种组合方法避免了通常价值投资中可能存在的‘价值投资陷阱’——即某些看似‘便宜’的股票并不会带来理想的收益。这种指数制定方式, 一方面通过加入预期市盈率部分防御了“价值投资陷阱”发生的可能, 另一方面通过引入企业价值等指标使得对高杠杆公司的关注有所降低, 使得指数业绩更真实的反应价值风格的作用”。回顾 MSCI 各风格指数的历史年度收益对比可以发现, 价值风

格的历史业绩一直排序位于前列,仅在极少数的年份表现欠佳(例如 2008/2011/2015 年),并且从 1976 年至 2016 年的 40 年间, MSCI 价值风格指数获得最高的年化收益(14.5%)和第二名收益风险比(0.88),这也再次证明了正确的价值投资的确能够在长期投资中带来理想收益。

当然,价值因子的选择不局限于 MSCI 的三个因子,我们对大量的价值因子进行了计算和统计,将显著有效的因子的表现及其在不同市场环境(牛市、熊市、震荡市)中的表现都进行了统计。回溯结果显示,价值因子的确对未来收益有一定的预测效果,并且根据不同市场环境中表现出的超额收益情况,可以总结出,即使没有 MSCI 结果表现得强势,但在国内仍可以看作顺周期的风格,在长期投资中可以带来稳定的较高的风险调整的收益。

价值因子结果示例:

图 12: 预测 PE(未来 12 个月) 分组净值



数据来源: 东北证券, Wind

表 5(1): 预测 PE(未来 12 个月) 全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	22.68%	2.65%	35.49%	-73.25%
2	23.55%	3.51%	34.74%	-71.49%
3	21.30%	1.26%	33.49%	-71.26%
4	19.80%	-0.24%	33.26%	-69.54%
5	14.12%	-5.91%	35.29%	-66.92%

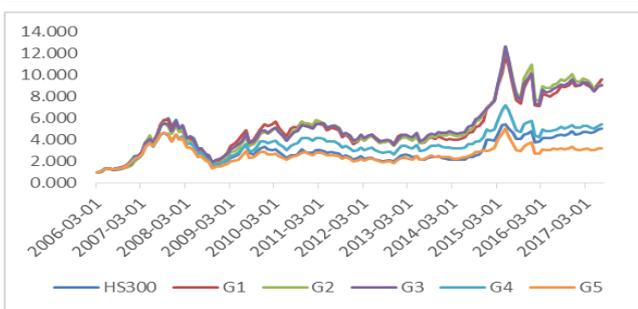
数据来源: 东北证券, Wind

表 5(2): 预测 PE(未来 12 个月) 不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	103.36%	-21.07%	26.88%	23.07%	11.59%	27.82%	-85.96%	-7.48%	49.46%
2	101.36%	-23.06%	31.46%	24.54%	13.06%	26.52%	-80.53%	-2.06%	47.00%
3	109.13%	-15.29%	29.39%	20.69%	9.22%	25.30%	-88.98%	-10.50%	42.00%
4	111.93%	-12.49%	31.89%	16.01%	4.54%	24.79%	-82.92%	-4.44%	40.26%
5	101.27%	-23.15%	36.07%	11.08%	-0.39%	25.02%	-85.34%	-6.87%	47.95%

数据来源: 东北证券, Wind

图 13: 市销率 PS(TTM) 分组净值



数据来源: 东北证券, Wind

表 6(1): 市销率 PS(TTM) 全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	26.94%	6.90%	36.81%	-70.39%
2	26.47%	6.44%	36.95%	-71.47%
3	25.65%	5.61%	34.73%	-65.73%
4	20.36%	0.33%	32.74%	-66.53%
5	16.10%	-3.94%	33.39%	-70.47%

数据来源: 东北证券, Wind

表 6(2): 市销率 PS(TTM)不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	125.45%	1.03%	32.07%	22.68%	11.21%	28.26%	-83.33%	-4.86%	46.99%
2	120.22%	-4.20%	37.15%	23.68%	12.21%	27.36%	-81.67%	-3.19%	46.78%
3	117.75%	-6.67%	31.44%	22.01%	10.53%	25.87%	-76.94%	1.53%	45.82%
4	102.39%	-22.04%	31.81%	18.26%	6.79%	24.47%	-77.16%	1.32%	41.85%
5	100.53%	-23.89%	29.66%	15.90%	4.43%	24.98%	-91.20%	-12.73%	43.48%

数据来源: 东北证券, Wind

2.1.4. 市值、动量、波动率和流动性因子定义

与其他类型因子相比, 动量、波动率、流动性和市值被投资者熟知的程度更甚。

市值效应反应小市值股票相对大市值股票的风险溢价。自 Fama-French 提出三因子模型至今, 市值效应一直成为研究组合收益的重要影响因素, 并且也成为了各种风格指数成立的基石。经验显示, 市值风格是顺周期风格, 即该风格可以市场处于上涨阶段保持获益。

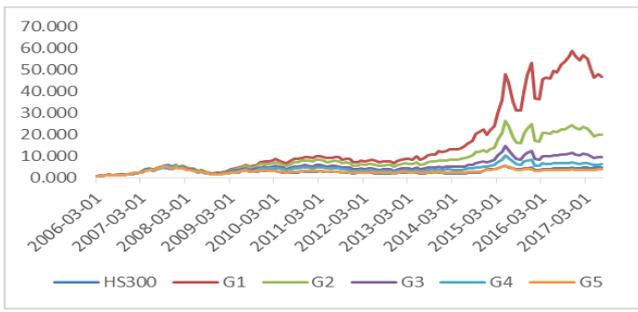
学术上首次记录动量效应是 1993 年 UCLA 两位学者发现通过持有近期表现优异的股票组合 3 到 12 个月可以产生非常丰厚的收益。而实际投资中, 选择“强者”作为标的的做法可以追溯到更久之前。经验显示, 动量风格是持续型风格, 即该风格可以在持续的趋势中获益。如图 10, 可以发现, 动量风格指数的历史年化收益仅次于价值, 约为 13.5%。

低波策略在资产配置中较为常见, 而经验显示, 低波组合在股票市场中也能够在长期投资中产生丰厚的风险调整后收益。也因此, 低波风格的 smart beta ETF 在国外也已经有了一定规模和受众。经验显示, 低波风格是防御型风格, 即与质量风格相似, 该类风格能够在市场处于下跌阶段保持获益。低波指数虽然在年化收益落后于其他风格指数, 但是凭借其极低的年化波动, 风险调整后的收益能够超过 0.9, 是所有风格指数中最高的一支。

动量、波动率、流动性和市值风格研究众多, 并且被反复证实其对组合收益的显著影响。虽然例如市值等风格在组合中表现的波动和回撤较大, 但其对绝大多数组合的影响力很大, 使用好这一类风格可以带了很可观的收益。而动量作为持续性风格, 能够在各种市场环境中提供优异的回报, 但需要注意的是历史上也多次出现动量崩塌事件, 有可能带来较大的损失。而低波风格是极少数在震荡行情和下跌行情中也能提供收益的风格, 并且长期来看, 该风格能够提供较高的风险调整后的收益。

结果示例:

图 14: 市值分组净值



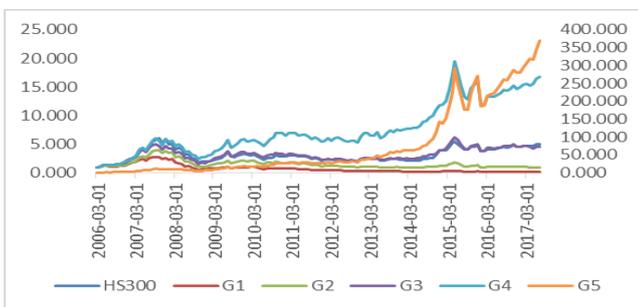
数据来源: 东北证券, Wind

表 7(2): 市值不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	120.82%	-3.60%	50.97%	41.57%	30.10%	30.31%	-47.18%	31.29%	56.66%
2	117.95%	-6.47%	47.60%	32.80%	21.33%	29.52%	-60.47%	18.01%	55.17%
3	111.30%	-13.12%	42.97%	25.99%	14.52%	28.90%	-70.09%	8.38%	52.88%
4	108.64%	-15.78%	38.40%	21.98%	10.51%	28.07%	-78.82%	-0.34%	51.68%
5	112.61%	-11.81%	29.67%	14.46%	2.99%	24.62%	-88.92%	-10.45%	39.95%

数据来源: 东北证券, Wind

图 15: 1 年涨跌幅分组净值



数据来源: 东北证券, Wind

表 8(2): 1 年涨跌幅不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	68.33%	-56.09%	26.89%	-9.58%	-21.05%	27.82%	-116.17%	-37.70%	47.73%
2	88.60%	-35.82%	28.73%	4.61%	-6.87%	25.34%	-100.28%	-21.81%	44.93%
3	108.38%	-16.05%	33.33%	15.71%	4.24%	26.54%	-80.22%	-1.75%	40.49%
4	117.03%	-7.39%	33.05%	27.34%	15.87%	25.32%	-65.63%	12.85%	42.46%
5	177.73%	53.31%	42.15%	52.51%	41.04%	27.56%	-54.18%	24.29%	51.63%

数据来源: 东北证券, Wind

表 7(1): 市值全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	43.03%	22.99%	42.09%	-66.20%
2	35.01%	14.97%	40.95%	-67.83%
3	27.94%	7.91%	39.28%	-67.98%
4	23.59%	3.56%	37.92%	-69.11%
5	18.14%	-1.89%	33.02%	-69.95%

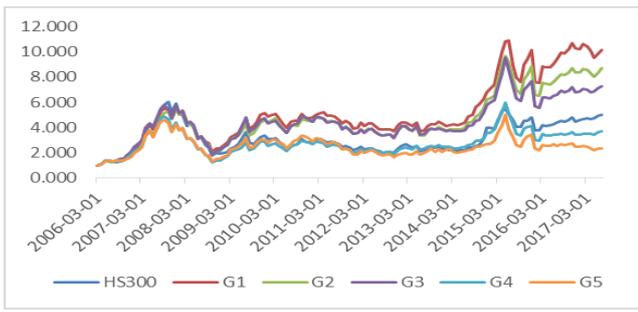
数据来源: 东北证券, Wind

表 8(1): 1 年涨跌幅全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	-10.53%	-30.56%	34.90%	-94.96%
2	5.07%	-14.96%	33.58%	-77.46%
3	19.27%	-0.77%	34.16%	-68.40%
4	30.75%	10.71%	33.63%	-60.31%
5	61.14%	41.11%	40.30%	-55.82%

数据来源: 东北证券, Wind

图 16: Historical sigma 分组净值



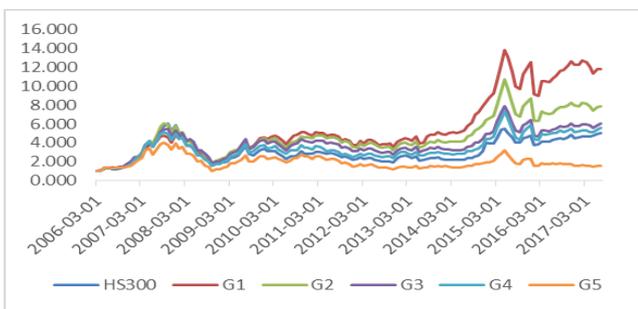
数据来源: 东北证券, Wind

表 9(2): Historical sigma 不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	113.70%	-10.72%	32.79%	20.22%	8.75%	23.12%	-64.19%	14.28%	42.54%
2	112.90%	-11.52%	28.34%	19.72%	8.25%	25.12%	-69.18%	9.30%	43.28%
3	117.84%	-6.58%	29.07%	19.08%	7.61%	26.11%	-79.38%	-0.90%	43.94%
4	108.98%	-15.44%	32.63%	17.93%	6.46%	25.76%	-99.88%	-21.41%	43.68%
5	106.36%	-18.07%	36.90%	14.43%	2.96%	29.99%	-97.57%	-19.09%	51.79%

数据来源: 东北证券, Wind

图 17: 6 个月简单日平均换手率分组净值



数据来源: 东北证券, Wind

表 10(2): 6 个月简单日平均换手率不同区间表现统计

	牛市			震荡市			熊市		
	收益率	超额收益	波动率	收益率	超额收益	波动率	收益率	超额收益	波动率
1	105.69%	-18.73%	28.41%	26.50%	15.03%	27.30%	-74.17%	4.31%	43.74%
2	119.64%	-4.78%	29.00%	25.97%	14.49%	27.02%	-81.72%	-3.25%	49.87%
3	115.34%	-9.09%	30.86%	23.83%	12.36%	27.22%	-83.78%	-5.31%	48.86%
4	116.73%	-7.69%	35.61%	21.07%	9.60%	27.86%	-85.56%	-7.09%	52.00%
5	95.23%	-29.19%	36.70%	13.90%	2.42%	28.64%	-86.33%	-7.85%	54.67%

数据来源: 东北证券, Wind

表 9(1): Historical sigma 全历史表现统计

	收益率	超额收益	波动率	最大回撤
1	25.82%	5.79%	32.42%	-63.75%
2	24.68%	4.65%	32.86%	-65.30%
3	23.54%	3.50%	34.20%	-67.94%
4	17.83%	-2.20%	35.05%	-74.48%
5	15.28%	-4.75%	39.19%	-72.27%

数据来源: 东北证券, Wind

表 10(1): 6 个月简单日平均换手率历史表现统计

	收益率	超额收益	波动率	最大回撤
1	26.93%	6.89%	31.44%	-62.30%
2	24.00%	3.96%	33.47%	-70.19%
3	21.71%	1.67%	33.66%	-67.23%
4	21.52%	1.48%	35.48%	-69.67%
5	12.39%	-7.65%	40.15%	-74.33%

数据来源: 东北证券, Wind

本文细节可参考文章《多因子系列 1:单因子回溯和特征分析》。

2.2. 因子筛选

2.2.1. 模型说明

一般在对线性模型进行变量筛选时，通常考察的指标是系数T值、可决系数 R^2 或者F统计量。对于定价模型，筛选因子的方法则存在较大的不同。评价定价模型解释水平高低的主要方法是检验其截距项是否显著为0 (Merton, 1973)。在上节内容中，我们对单因子显著性进行了分析，初步筛选出了一些表现较好的因子。而在进行多因子模型构建时，需要对因子进一步筛选。

Harvey&Liu (2016/2017) 通过构建新的检验指标，通过对比截距项变化对已有因子进行了筛选。我们将 Harvey&Liu 的面板数据做法压缩到截面数据上使用，同时对统计量的计算上进行相应的改进，同时提出一种计算检验统计量显著性的标准，来确定某个因子是否能够提供超额信息。

假设共有M个alpha因子，已经确定了其中k个因子具有较好的收益解释和预测能力，需要判断在剩余的因子 $\{X_{k+j}^s, j=1, \dots, M-k\}$ 是否仍有其他因子能够解释、预测股票收益。此时，基准模型如下：

$$r - r_f = \alpha^b + X^b f^b + \varepsilon \quad (2.5)$$

其中，在每一时点t，股票数量为N， $1 \leq i \leq N$ ，上角标b表示基准模型(baseline model)， X^b 的第i行为t时刻第i只股票的k个风格因子暴露， α^b 为基准模型的截距项， f^b 为回归计算出的因子斜率列向量。记 $X_{k+j}^s (j=1, \dots, M-k)$ 为备选的单个因子，上角标g表示扩展模型(augmented model)，将其添加到模型(2.5)中，得到如下扩展模型：

$$r - r_f = \alpha_{k+j}^s + X^b \tilde{f}^b + X_{k+j}^s f_{k+j}^s + \tilde{\varepsilon} \quad (2.6)$$

如果 X_{k+j}^s 有助于解释截面收益，那么 α_{k+j}^s 会比 α^b 更接近0，而如果 X_{k+j}^s 的信息可以被其他因子解释，那么理论上两个模型是一致的。

利用t时刻的截面股票收益率和各风格的暴露数据，对(2.5)和(2.6)的中的模型进行回归，并得到截距估计值 $\hat{\alpha}^b$ 和 $\hat{\alpha}_{k+j}^s$ ，及对应标准误为 se^b 和 se_{k+j}^s 。据此构建如下统计量：

$$SI(X_{k+j}^s) = \left(\frac{|\hat{\alpha}_{k+j}^s| - |\hat{\alpha}^b|}{se^b} \right) / \frac{|\hat{\alpha}^b|}{se^b} = \frac{|\hat{\alpha}_{k+j}^s| - |\hat{\alpha}^b|}{|\hat{\alpha}^b|} \quad (2.7)$$

统计量SI(scaled intercept)衡量了两个回归方程由标准误差调整的截距项变化的百分比。标准误差调整的这一做法将噪声影响纳入考量，使得估计误差比较大的收益序列的权重被降低，进而提高估计精度，同时也调整了极端值出现带来的影响。需要注意的是，对扩展模型截距项进行标准化的是基准模型截距项标准误。此种设定，保证了如果两个模型是没有差别的，那么 $SI(X_{k+j}^s) = 0$ 。在Harvey&Liu原始报告中，他们使用面板数据，对于每个新加入的因子都可以计算相应的标准误差调整的截距项的变化，原文中通过所有面板上调整的均值 SI^m 进行判定。在他们的 SI^m 中对 $\hat{\alpha}^b$ 和 $\hat{\alpha}_{k+j}^s$ 进行标准误差调整的都是基准组合的标准误 se^b ，这使得如果两个模型没有差别，则 $SI^m = 0$ ，便于进行假设检验的原假设的设定。

对于每一备选因子 X_{k+j}^s ，均可得到一个统计值SI。由于该统计量给出的是相比于基准模型添加的因子使得标准化截距项“变小”的比例，且负向越大越好，因此该统计量越小，则意味着该因子越有效。因此我们可以将单个因子的原假设

H_0 : 第 $k+j$ 个因子不能提升模型解释能力, $SI(X_{k+j}^g) = 0$

变化为检验 $M-k$ 个因子均无法添加到基准模型中, 即 SI 最小的因子无法添加到模型中。为此, 构建如下统计量:

$$SI^{Min} = \text{Min} \left\{ SI(X_{k+j}^g) \right\}_{j=1}^{M-k} \quad (2.8)$$

2.2.2. 检验过程

检验最小值可以控制数据探测误差——我们可能会偶然的从 $M-k$ 个因子中选出某个因子。由于涉及到多个因子以及原假设的分布未知, 可以通过 Bootstrap 方法计算 $M-k$ 个因子联合分布 SI^{Min} 在原假设下的经验分布。

下面对 Bootstrap 模拟步骤进行说明。

1. 在每个截面, 计算(2.1)和(2.2), 得到截距估计值和标准误。据此得到实际的统计值序列 $\{SI_{k+j}^g\}_{j=1}^{M-k}$, 并计算得到统计值 SI^{Min} ;
2. 将 $M-k$ 个因子 $X_{k+j}^g (j=1, \dots, M-k)$ 按模型(2.4)进行回归, 得到 \tilde{X}_{k+j}^g ;
3. 从 $1, 2, \dots, N$ 中随机重复抽取 N 个值, $(n_1, n_2, \dots, n_N), 1 \leq n_i \leq N$ 。按此序列对基准模型的因子矩阵 X^b 、 \tilde{X}_{k+j}^g 和收益率序列 r 的 (n_1, n_2, \dots, n_N) 行进行取样, 保证截面相关性, 得到 $\{X_{n_i}^b\}_{i=1}^N$ 、 $\{\tilde{X}_{n_i}^g\}_{i=1}^N$ 和股票收益序列 $\{r_{n_i}\}_{i=1}^N$;
4. 使用 3 中得到的数据进行(2.1)和(2.2)的回归, 得到模拟统计值 SI_1^{Min} 。
5. 重复步骤 3 和 4 共 S 次 (文中结果取 $S=10000$), 据此得到模拟统计值序列 $\{SI_s^{Min}\}_{s=1}^S$ 。并计算显著性检验指标 $p = \sum_{s=1}^S I\{SI_s^{Min} < SI^{Min}\} / S$, 其中 I 为示性函数。

在计算过程中, 最开始的基准模型不包含任何因子。每次计算, 可以使得扩展模型 SI 取最小的风格因子, 根据其模拟 SI_s^{Min} 值来判断该因子是否可以添加到基准模型中。如果可以, 则将包含该因子的模型作为新的基准模型, 其余因子作为备选因子。重复上述过程, 直到没有新的因子通过检验。

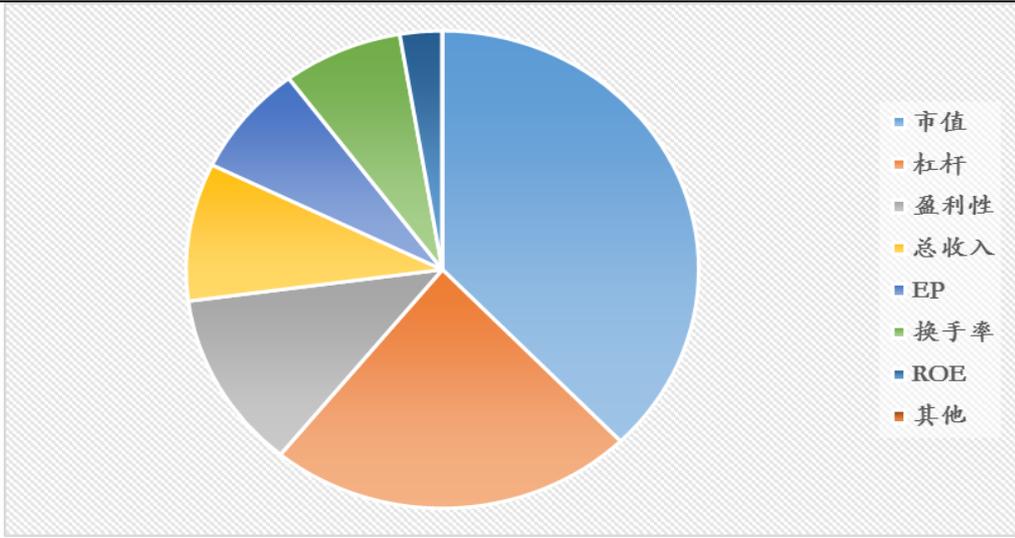
2.2.3. 结果展示

在 2006.03—2017.06 的 136 个月里, 因子筛选出频率依次为: 市值-杠杆-盈利-营业收入-EP&换手-ROE。具体频次见图 18。我们采用滚动 36 个月的截面因子筛选结果, 选择频次较高的因子作为最终选股因子, 采用因子等权方法选取全市场可交易股票得分最高的 10% 的股票, 计算超额收益(相对于万得全 A) 结果。

通过本节介绍的因子筛选方案, 对原始因子池进行精简, 可以在不损耗信息的情况下减少因子数量, 提高因子信息使用效率, 进而提升收益。图 9 的精致结果显示, 无论是否将市值作为选股因子, 均可以提供较高的超额收益, 特别地, 剔除市值的其余因子的超额收益稳定性更高。表明 Harvey 筛选因子的方法是个较为有效的因子筛选方法。

本文细节可参考文章《多因子系列 2: 因子筛选》。

图 18: 因子频次统计



数据来源: 东北证券

图 19: 回溯超额收益结果



数据来源: 东北证券, Wind

2.3. 特质波动率

2.3.1. 研究逻辑

波动率是风险度量的一种方式, 可将该指标应用于指数构建、资产配置和个股选择。对于个股, 基于多因子模型, 可以将收益进行如下拆分:

$$r_t = \alpha_c + \sum_{s=1}^K X_{ts} f_s + u_t \quad (2.9)$$

其中 r_t 为个股超额收益, α_c 为截距项, f_s 为因子收益, u_t 为残差项。

基于该收益分解模型, 可以对个股波动率进行拆分, 即其是由公共因子风险和个股特质风险构成。前者反映的是所有个股受市场共有风险的影响, 大小与个股因子暴露值有关; 后者则是仅与个股特征有关的风险。因此有理由可以相信该特质风险中

包含有用的定价信息，在本报告中我们将对其进行检验。

对于模型(1.1)，有如下几点需要明确：一，模型中因子应如何确定，即哪些因子应被纳入模型；二，如何基于回归残差值进行指标构建。

对于第一点，目前的分析多是基于已有模型，如 CAPM、Fama-French 三因子模型和 Carhart 四因子模型，分别表示如下：

CAPM:

$$r_t = \alpha_c + \beta_1 RMF_t + u_t \quad (2.10)$$

Fama-French 三因子模型:

$$r_t = \alpha_c + \beta_1 RMF_t + \beta_2 SMB_t + \beta_3 HML_t + u_t \quad (2.11)$$

Carhart 四因子模型:

$$r_t = \alpha_c + \beta_1 RMF_t + \beta_2 SMB_t + \beta_3 HML_t + \beta_4 UMD_t + u_t \quad (2.12)$$

其中 RMF_t 为市场超额收益； SMB_t 为规模因子， HML_t 为账面市值比因子， UMD_t 为动量因子。

对于第二点，以回归残差的标准差作为特质波动率的度量（还有研究以其偏度和峰度作为度量，本报告中不对其进行分析）。

通过分析，我们会产生如下疑问，每一时期，对于每一股票，使用相同的因子是否合理。为对这一问题进行分析，我们使用了如下 10 个因子作为备选因子，基于此进行个股模型构建。这十个因子分别为市场、BP、盈利、成长、杠杆、流动性、动量、非线性市值、市值和波动率。每一期，对于每只股票，基于逐步回归方法（BIC 准则），筛选出入选因子，进行回归计算残差值。因子说明见表 11。

表 11: 备选因子说明

风格因子	定义	代表含义
市场	股票收益市值加权扣除无风险收益率	市场收益
BP	Book-to-Price, 市净率的倒数	价值
盈利	预测 EP、CP、EP-TTM	盈利性
成长	盈利增长率、销售收入增长率	成长
杠杆	市场杠杆、资产负债率、账面杠杆	财务杠杆
流动性	换手率（月均、季均和年均）	流动性
动量	Relative Strength, 超额收益	动量
非线性市值	股票市值的立方，剔除线性关系	中盘
市值	股票市值的对数	大盘
波动率	日收益标准差、历史标准差	波动性

数据来源：东北证券

对于第二点，现有方法是基于回归期所有残差值计算其波动率，即：

$$STD^o = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (\hat{u}_t - \bar{\hat{u}})^2} \quad (2.13)$$

参考 Blitz、Huij 和 Martens (2011), 将(1.4)修正为:

$$STD^N = \sqrt{\frac{1}{T_0 - 1} \sum_{t=T_0+1}^T (\hat{u}_t - \bar{\hat{u}})^2} \quad (2.14)$$

对比来看, (2.13)中残差估计区间为整个回归区间; (2.14)中计算个股特质波动率使用的残差为最近时间段的价值。对于这一点可以从如下角度进行理解: 较长时间段的估计窗口是为保证回归估计的准确度, 而仅使用距离最近的值则是为了信息使用的有效性。

此外, 对于回归使用的因子收益, 我们使用的是基于 Barra 模型的回归结果, 而非基于多空组合得到的收益序列。下面我们将通过历史数据对上述方法进行检验, 以判断其有效性。

2.3.2. 回测检验

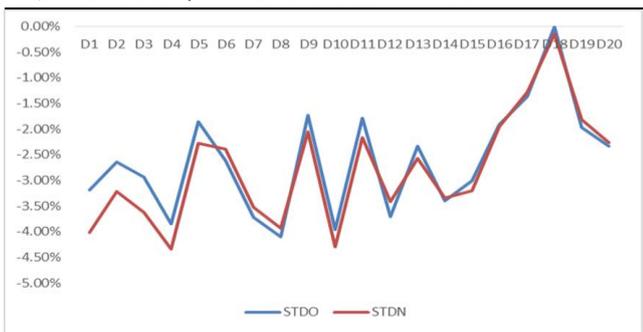
在这一部分我们对前文所述方法进行回测检验。具体来说, 所涉及的股票池为全部 A 股, 回测区间为 2006 年 7 月至 2017 年 9 月。回测流程如下:

- (1) T 时刻, 利用前推 N 个交易日数据和因子收益数据, 进行逐步回归, 筛选出所需模型; 据此得到个股残差收益率数据, 并计算因子值;
- (2) 对因子值进行升序排列, 将所有股票等分为 K 个组合, 等权配置;
- (3) T+1 时刻, 剔除停牌股票, 以收盘价买入股票, 组合持有 M 个交易日;
- (4) 重复上述操作, 计算组合净值、评价指标; 同时计算得到因子信息系数(IC)

对于上述流程, 涉及的可变参数为: 计算因子值的区间长度 N, 预测收益的区间长 M 度, 划分组合个数 K。在本报告中, 上述参数分别为: N=60 (一个季度), M=20 (一个月), K=10。下面给出具体回测结果。

首先对因子秩相关系数 IC 进行分析。我们计算了上述两个因子每日 IC 和每一持有日 IC 值, 具体见图 20 和表 12。由图 1 可以看出, STDO 和 STDN 逐日 IC 存在较大的波动, 没有明显的衰减趋势 (在 20 个交易日的持有期内)。6 个交易日之后, STDO 和 STDN 走势基本一致; 18 个交易日左右, IC 趋于 0, 随后又变为负值; 前 5 个交易日, STDN 的 IC 绝对值更大, 即个股因子值与未来收益相关性更高。由表 2 可以看出, STDO 和 STDN 的 IC 均是显著的; 且后者均值绝对值更大, 即有效性更强。基于图 1 和表 2, 可以发现 STDO 和 STDE 均具有较强的有效性。

图 20: 因子每日 IC (N=60, M=20)



数据来源: 东北证券, Wind

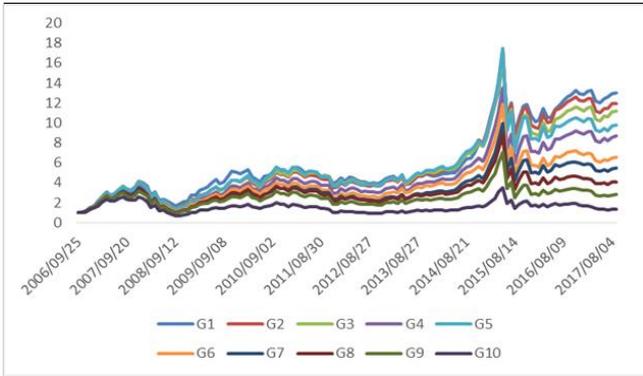
表 12: 因子 IC (N=60, M=20)

	STDO	STDN
均值	-6.02%	-7.36%
T 值	-5.116	-6.685

数据来源: 东北证券, Wind

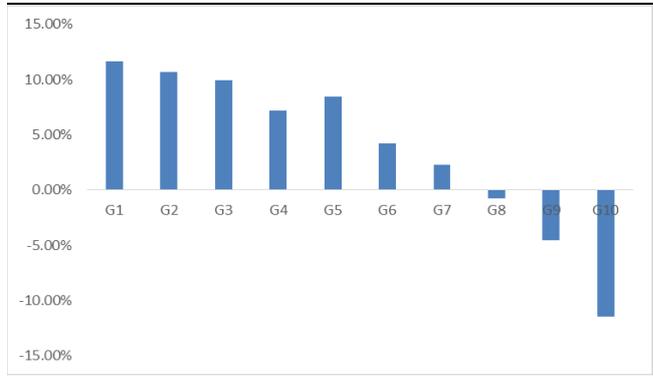
下面对分组净值走势进行分析，具体见图 21、图 22、图 23 和图 24。由图 21 和图 23 可以看出，10 组组合具有较好的区分度，且与因子值有较好的线性关系，由图 22 和图 24 可以更为明显地看出这一结论。随着因子值的增大，组合超额收益（相对 WIND 全 A）依次降低。且与 STDO 相比，STDN 在多头组合中收益更高，而在空头组合中收益更低，即具有更好的区分能力。

图 21: 净值走势--STDO



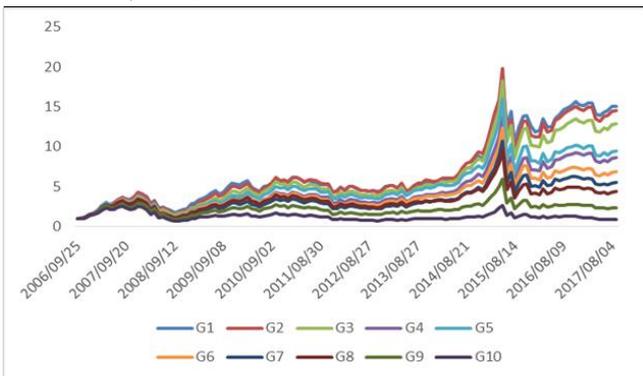
数据来源：东北证券，Wind

图 22: 年化超额收益率 --STDO



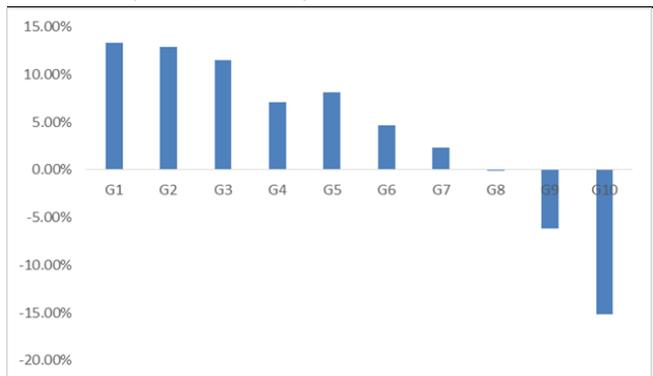
数据来源：东北证券，Wind

图 23: 净值走势--STDN



数据来源：东北证券，Wind

图 24: 年化超额收益率 --STDN



数据来源：东北证券，Wind

由上一部分因子检验结果可知，STDO 和 STDN 具有较强的有效性。据此，可以进行如下策略构建：

- (1) 因子：STDO 和 STDN，基于过去 60 个交易日数据进行因子构建；
- (2) 调仓频率：月度（持有 20 个交易日）；
- (3) 持有组合：按因子值升序排列，等分为 10 组；持有因子值最小的一组股票；
- (4) 加权方式：等权持仓。

策略回测结果见表 13。由表 13 可知，STDO 和 STDN 多头波动率和最大回测均比较相似：前者年化收益为 25.80%，后者则为 27.50%。对于空头组合，STDO 和 STDN 的年化收益分别为 2.76%和-0.99%，即后者可以更好地将表现较差的股票筛选出来。对于多空组合，STDN 年化收益为 28.77%，高于 STDO（22.43%）；多空组合波动率和最大回测均有很大幅度的降低。这里之所以对空头进行分析，是因为虽然不能有效的通过做空获取其收益，但是可以对该类型股票进行一定程度的规避，进而降低损失的可能性。

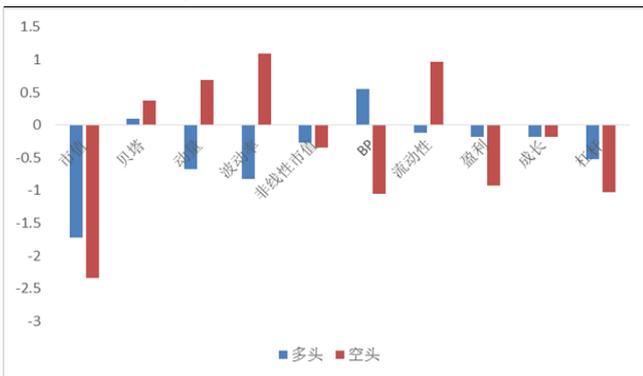
表 13: 策略表现

因子	组合	年化收益	超额收益	波动率	最大回撤	Sharpe
STDO	多头	25.80%	11.60%	36.31%	59.26%	0.711
	空头	2.76%	-11.45%	45.42%	74.58%	0.061
	多空	22.43%	8.23%	18.17%	16.20%	1.235
STDN	多头	27.50%	13.30%	36.17%	59.49%	0.76
	空头	-0.99%	-15.19%	45.46%	75.17%	-0.022
	多空	28.77%	14.57%	17.26%	16.65%	1.666

数据来源：东北证券

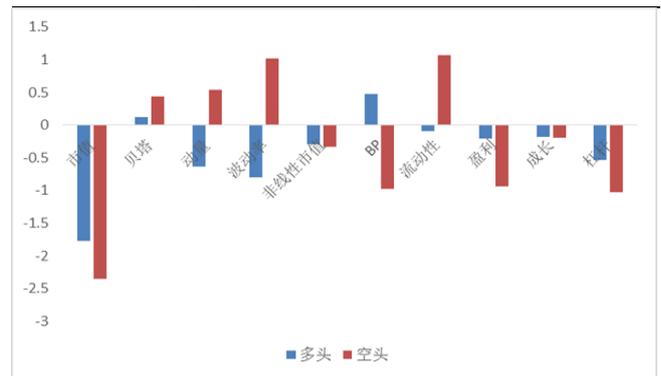
为对因子策略表现有更为细致的了解，我们对多空组合风格暴露进行了分析，具体见图 25 和图 26。可以看出，两种策略对应的多头和空头暴露分别具有较大的相似度。具体来说，对于多头组合，其主要暴露于市值因子，即整体偏小盘；在动量、BP 上有一定的暴露，不过相对较小；在波动率上有负向暴露，不过并不大。对于空头组合，其在市值、动量、波动率、BP、流动性、盈利和杠杆因子上均有较大的暴露。相对多头，空头组合暴露于更多的因子，这也导致其波动率和回撤均较大，且收益率也表现较差。

图 25: 风格暴露 -- STDO



数据来源：东北证券，Wind

图 26: 风格暴露 -- STDN



数据来源：东北证券，Wind

2.4. 新因子探索——择时因子

本节为我们考虑一个新的因子——择时因子，即通过择时的思想合成新因子，并检验该因子的有效性。

2.4.1. 择时因子的由来

在传统的因子构建和检验中，我们通常将因子在横截面上进行排序或其他数据处理。这样做的前提是不同股票之间的因子是可以相互比较的。但是对于财务因子、估值因子等跟行业、市值密切相关的因子则不能直接进行比较。因此，我们需要对这类因子进行行业中性，有必要的还进行风格（市值）中性。传统的行业中性的做法是对申万/中信一级行业进行哑变量回归取残差，其本质是对同一个一级行业内部的股票的因子进行中心化（Zero-centered 或者 Mean-subtraction）处理，即同一个行业内的各个股票的因子值减去该行业内的所有股票的因子的平均值。诚然，我们不否认这种做法的合理性，但我们同时应该看到这样的做法无法更细分的子行业进行区分。

图 27: 复星医药股价 VS 恒瑞医药股价



数据来源: 东北证券, Wind

图 28: 复星医药 PE VS 恒瑞医药 PE



数据来源: 东北证券, Wind

例如, 我们以医药行业中的两个龙头股票复星医药 (600196.SH) 和恒瑞医药 (600276.SH) 进行对比。我们发现, 恒瑞医药的 PE 几乎都比同一时期的复星医药更高。如果按照上述行业中性做法的观点, 再加上我们已然知道 A 股历史上平均来看高 PE 的股票表现不如低 PE 的股票, 那么我们可能会认为恒瑞医药的表现应该要强于复星医药。事实上恒瑞医药的股价一直在创新高, 而复星医药的股价跟大盘走势更为接近。其实仅仅依赖 PE 并不能得出哪个股票更值得投资, 本文的目的也不是去研究 PE 和股价之间的关系。我们只想通过这个例子说明, 对于横截面行业中性的做法而言, 仍然有其不足之处。

那么是不是深入到更细分领域做更细分的行业中性就能解决这个问题了呢? 理论上可以。但是考虑到申万二级有 104 个细分子行业, 申万三级有 227 个更细分的子行业。而这些细分子行业的数量不一, 有些行业的样本数明显不足, 导致在做平均值受到极端情况影响较大, 统计上意义也不大。虽然可以重新对行业进行定义和分类, 但这可能需要专业的水平以及大量的人工标注, 工作量巨大, 因此我们也不推荐这样的做法。

为此, 我们提出我们的一个思考: 如果一个公司的主营业务没有发生巨大的变化, 那么市场对于其估值是否存在一个合理的估值中枢? 我们还是以复星医药和恒瑞医药为例。根据 Wind 最新数据显示: 恒瑞医药的主营业务构成分别是 72.48% 业务是针剂药, 26.25% 是片剂药, 1.11% 原料药, 其他业务仅占比 0.16%。而复星医药的主营业务构成分别是 70.13% 药品制造与研发, 18.21% 医学诊断与医疗器械, 11.47% 是医疗服务, 其他业务 0.19%。如果不是专业人员, 恐怕也很难分清这两者的主营业务的差别及应该如何估值。因此, 在请教了医药行业分析师之后, 我们得知恒瑞医药是一个专注做研发的公司, 而复星医药的业务全面, 有研发、有制药, 有医疗器械, 也有医疗服务, 也有收购公司做类 PE 业务。而从市场的估值来看, 恒瑞医药的平均估值在 40~50 之间, 而复星医药则在 20 倍左右。从市场的表现我们可以逆向推断, 市场对于专注研发的公司给予更高的估值水平, 而对于业务分散的公司估值相对要低得多。

如果我们认可“市场普遍对于大类行业及其细分子行业存在估值中枢”, 那么这个估值中枢就能帮我们加以判断某个股票现在是处于估值中枢之上(贵)还是之下(便宜)。因此, 只要这个公司的主营业务没有发生巨大变化, 那么其估值水平相对自

身历史就是可比的。借助这个可比性，我们可以剔除不同行业之间的影响：传统的横截面行业中性分析得出相对行业平均水平的贵与便宜，而我们从时间序列分析得出相对于自身的贵与便宜。对于这种在时间序列维度上分析构建而成的因子我们称之为择时因子，或者也可以把运用择时思想构建的因子称之为择时因子，其本质是一种因子的因子（Factor of Factor）的做法，只不过通常我们这里指的第一个因子是用“反转”因子，第二个因子是原始因子。其蕴含的逻辑同样是那些因子本身具有反转特性的因子。

衡量时间序列上的高和低的方法很多，我们这里仅选择较为简单的一种方法：分位数法，即计算过去一段时间序列上的当前因子值分位数，把因子的绝对值映射成[0,1]区间的百分数。这里时间周期我们选择过去3年、5年、10年。不选择全历史的原因在于不同股票起始时间不同，无法保证时间段的可比性。

构建完毕择时因子之后，我们希望选出那些相对自身而言被高估的股票做空，相对自身而言被低估的股票做多。然后这样的思路是否能够带来超额收益。

那么对于 PE 这个因子本身而言，分位数的做法有什么优点和缺点？我们认为有以下3个优点：

- 1) 首先是避免了绝对估值的不合理。关于这一点，我们在上一小节以复星医药和恒瑞医药的例子已经说明了这一点。
- 2) 其次是低估股比高估股有更小的下行风险。
- 3) 最后是价值股在横截面上的选择机会较成长股更多，选中成长股的概率更低。

同样，我们认为存在以下3个缺点：

- 1) 首先并不是所有因子都具有均值回复特点，估值因子可能陷入估值陷阱。
- 2) 其次是分位数的取值只能是0到1之间，在极端行情下，因子在0和1处钝化。
- 3) 最后是赚不到成长股的收益，换手率较高。

相比分位数方法，我们这里提供一些其他的思路，例如对时间序列上做 z_score，或者像构建技术指标一样构建基于因子的技术指标，对因子做技术形态的量化等等。

构建择时因子之后，我们将按照传统的单因子的思路进行检验其分组超额收益的单调性检验，多空稳定性检验，Rank_IC 的显著性检验以及换手率的计算等。

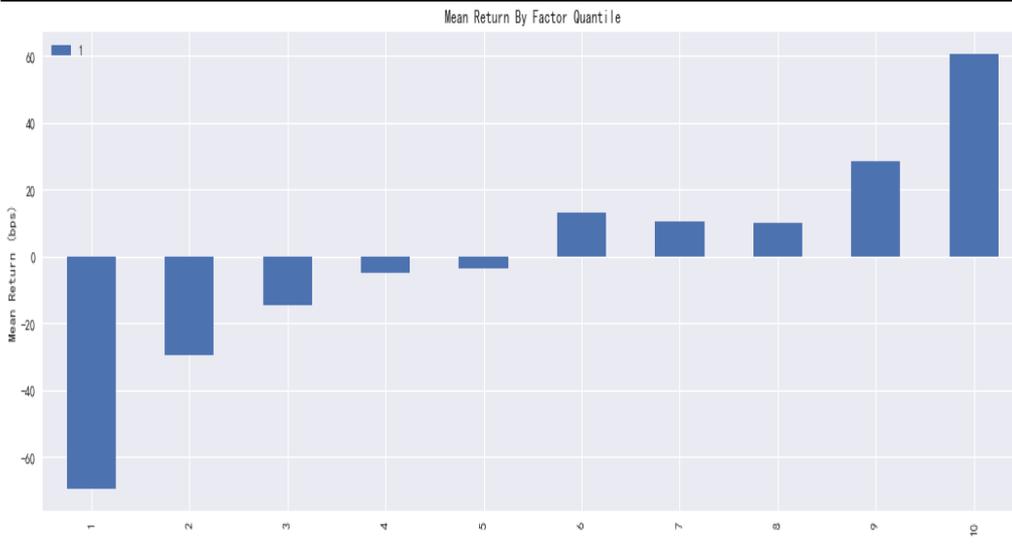
2.4.2. 分位数择时因子回测结果

对于因子的构建和检验，我们首先明确以下几个细节：

- 1) 在构建估值因子的分位数时，所用的是 PE 的倒数 EP，PE 均指的是 TTM。
- 2) 过去一段时间至少是3年。实际上在计算中是用到过去 3*240 个非停牌交易日数据进行计算。停牌期间由于 P 不变，因此 EP 没有意义。另外之所以使用 3*240 个交易日数据是为了计算方便，但缺点是无法对齐起始点。
- 3) 假设按照换仓日的前收盘价买入，不剔除换仓日涨跌停的个股，对于持有之后停牌、退市的股票，默认以停牌价或最后一个交易日格卖出，未扣除手续费。
- 4) 回测期间为 09 年 12 月 31 日至 2017 年 10 月 31 日，月度调仓。回测样本包括沪深 300，中证 500 和全 A，剔除上市不满一年的次新股，不剔除 ST 股。
- 5) 若非特别说明，因子的标准化、去极值的做法均按照前文多因子系列报告中的做法。所有因子均进行横截面上行业中性和市值中性。

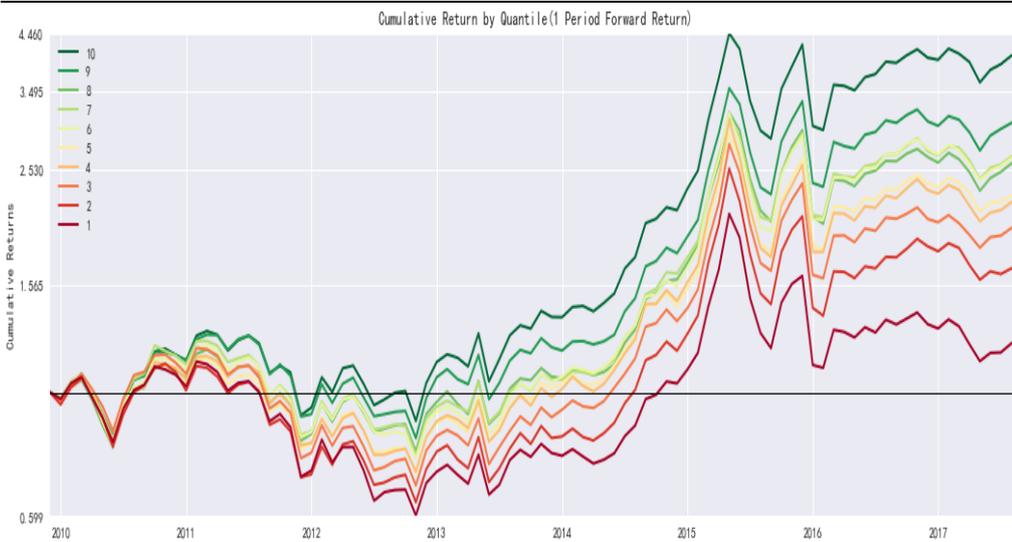
下面，我们以过去 3 年 EP 分位数因子（简记为 EP_Q_3Y）为例，展示我们的因子回测结果：EP_Q_3Y 在全 A 和中证 500 的选股能力较强，在沪深 300 的选股较弱。EP_Q_5Y 在全 A、沪深 300 和中证 500 的选股能力均较强。综合来看，EP_Q_3Y 和 EP_Q_5Y 均有稳定的超额收益，且多空收益稳定，即便是今年该因子仍然没有失效。

图 29: EP_Q_3Y 分组平均月度超额收益



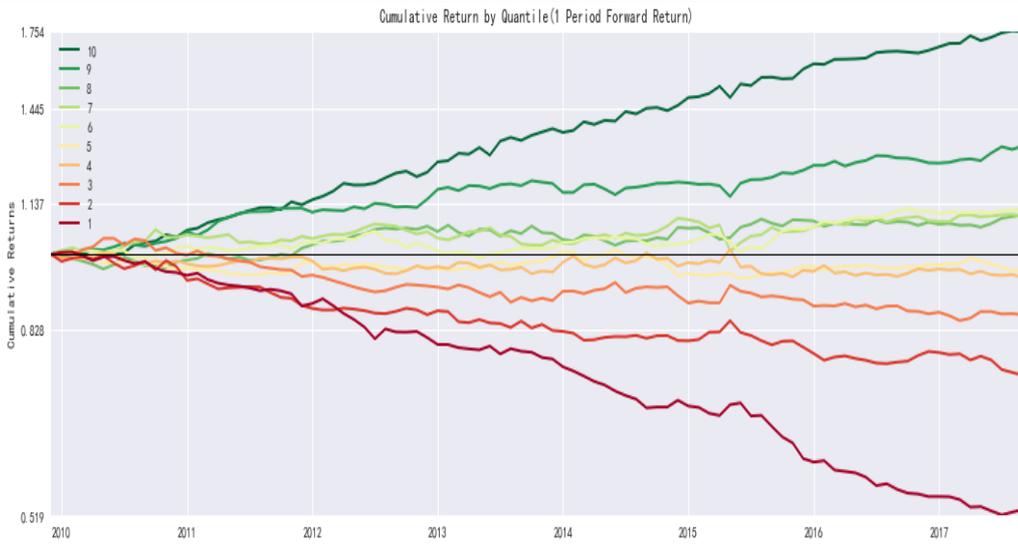
数据来源：东北证券，Wind

图 30: EP_Q_3Y 分组累计收益净值曲线



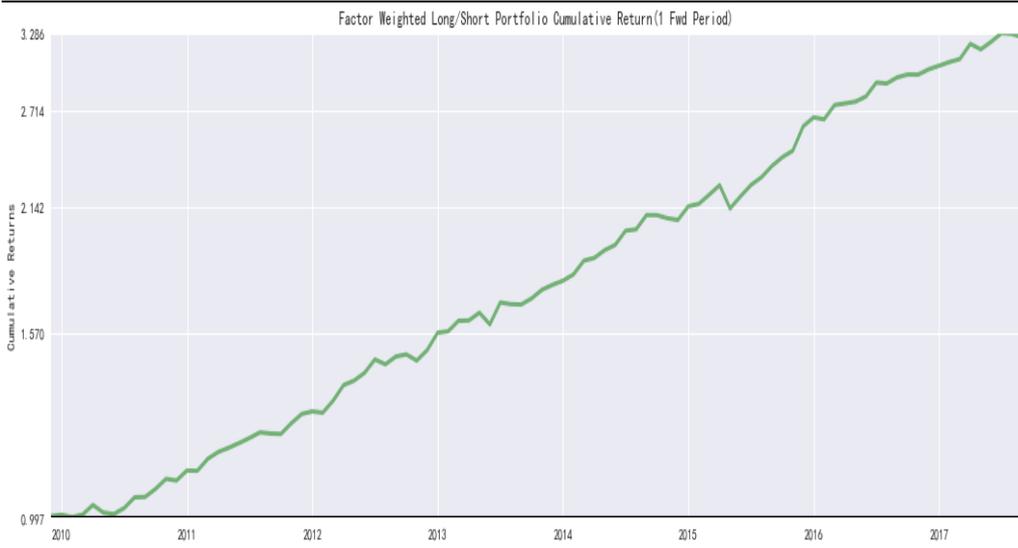
数据来源：东北证券，Wind

图 31: EP_Q_3Y 分组超额收益净值曲线



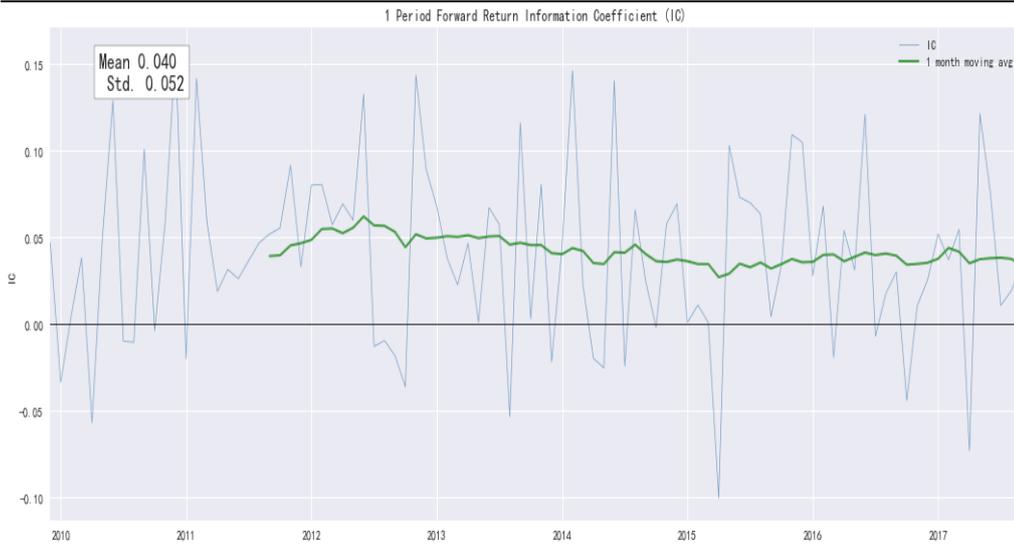
数据来源: 东北证券, Wind

图 32: EP_Q_3Y 多空收益净值曲线



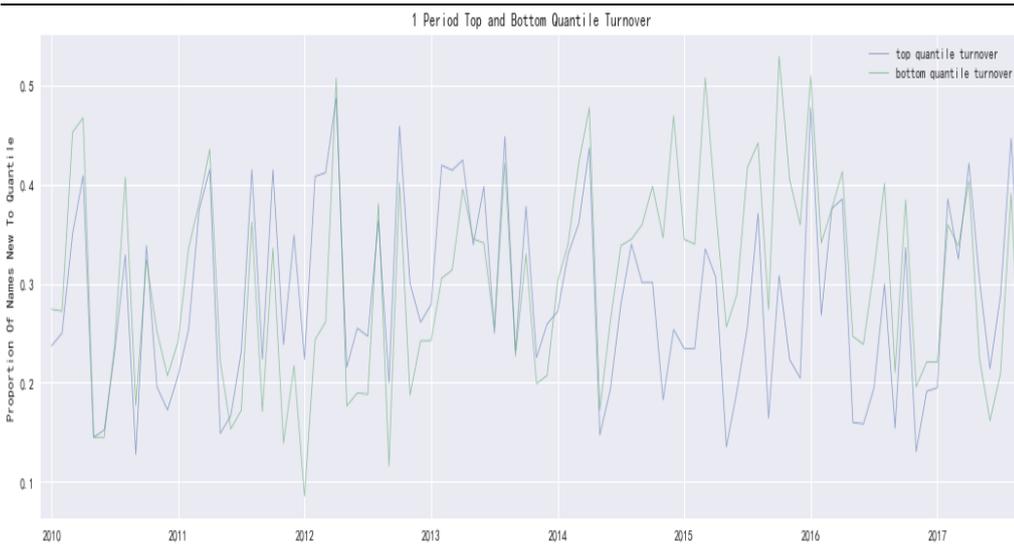
数据来源: 东北证券, Wind

图 33: EP_Q_3Y 月度 Rank_IC 曲线



数据来源: 东北证券, Wind

图 34: EP_Q_3Y 第 1 组 (空) 和第 10 组 (多) 单边换手率



数据来源: 东北证券, Wind

表 14: EP_Q_3Y 全 A 选股结果

	累计收益		第 10 组 超额收益	多空收益 (10-1)
	第 1 组	第 10 组		
胜率	54.84%	59.14%	73.12%	75.27%
年化收益率	2.94%	19.96%	7.48%	16.39%
年化波动率	31.25%	31.51%	3.75%	6.09%
Sharpe	0.09	0.63	1.99	2.69
最大回撤	47.32%	35.52%	2.81%	5.57%
最大回撤起始	2015/5/31	2015/5/31	2015/4/30	2015/4/30
最大回撤结束	2016/2/29	2015/9/30	2015/5/31	2015/5/31
收益回撤比	0.06	0.56	2.66	2.94

平均盈利	6.69%	7.48%	1.08%	2.00%
平均亏损	6.67%	6.06%	0.68%	0.87%
盈亏比	1	1.23	1.6	2.31
累计净值	1.25	4.11	1.75	3.25

数据来源：东北证券

表 15: EP_Q_5Y 全 A 选股结果

	累计收益		第 10 组 超额收益	多空收益 (10-1)
	第 1 组	第 10 组		
胜率	53.76%	59.14%	72.04%	76.34%
年化收益率	2.29%	19.45%	8.29%	16.54%
年化波动率	31.42%	31.45%	3.96%	6.07%
Sharpe	0.07	0.62	2.1	2.73
最大回撤	47.71%	31.97%	2.04%	3.08%
最大回撤起始	2015/5/31	2015/5/31	2010/1/31	2015/3/31
最大回撤结束	2016/2/29	2015/9/30	2010/6/30	2015/5/31
收益回撤比	0.05	0.61	4.07	5.37
平均盈利	6.92%	7.45%	1.18%	1.99%
平均亏损	6.73%	6.11%	0.62%	0.91%
盈亏比	1.03	1.22	1.89	2.18
累计净值	1.19	3.98	1.86	3.28

数据来源：东北证券

表 16: EP_Q_3Y 沪深 300 选股结果

	累计收益		第 10 组 超额收益	多空收益 (10-1)
	第 1 组	第 10 组		
胜率	51.61%	53.76%	52.69%	60.22%
年化收益率	-5.10%	3.36%	1.31%	8.85%
年化波动率	26.21%	28.32%	6.98%	10.12%
Sharpe	-0.19	0.12	0.19	0.87
最大回撤	54.99%	45.09%	10.78%	9.49%
最大回撤起始	2015/5/31	2015/5/31	2014/9/30	2010/2/28
最大回撤结束	2016/2/29	2016/2/29	2014/12/31	2010/6/30
收益回撤比	-0.09	0.07	0.12	0.93
平均盈利	5.42%	6.08%	1.43%	2.59%
平均亏损	6.07%	5.74%	1.33%	2.02%
盈亏比	0.89	1.06	1.08	1.28
累计净值	0.67	1.29	1.11	1.93

数据来源：东北证券

表 17: EP_Q_5Y 沪深 300 选股结果

	累计收益		第 10 组 超额收益	多空收益 (10-1)
	第 1 组	第 10 组		
胜率	52.69%	56.99%	59.14%	68.82%

年化收益率	-7.31%	9.37%	7.83%	17.74%
年化波动率	27.06%	29.11%	6.43%	10.64%
Sharpe	-0.27	0.32	1.22	1.67
最大回撤	57.24%	40.18%	6.21%	9.61%
最大回撤起始	2015/5/31	2015/5/31	2016/7/31	2016/7/31
最大回撤结束	2016/2/29	2016/2/29	2017/7/31	2016/12/31
收益回撤比	-0.13	0.23	1.26	1.85
平均盈利	5.23%	6.58%	1.83%	2.98%
平均亏损	6.49%	6.16%	1.06%	2.03%
盈亏比	0.81	1.07	1.73	1.47
累计净值	0.55	2	1.8	3.56

数据来源：东北证券

表 18: EP_Q_3Y 中证 500 选股结果

	累计收益		第 10 组 超额收益	多空收益 (10-1)
	第 1 组	第 10 组		
胜率	49.46%	56.99%	65.59%	78.49%
年化收益率	-6.75%	13.33%	7.69%	20.39%
年化波动率	31.51%	30.17%	5.30%	7.81%
Sharpe	-0.21	0.44	1.45	2.61
最大回撤	58.56%	38.54%	4.36%	4.65%
最大回撤起始	2010/3/31	2015/5/31	2015/3/31	2013/7/31
最大回撤结束	2012/11/30	2016/2/29	2015/5/31	2013/8/31
收益回撤比	-0.12	0.35	1.76	4.38
平均盈利	6.71%	7.14%	1.42%	2.37%
平均亏损	6.87%	6.13%	0.88%	1.26%
盈亏比	0.98	1.16	1.63	1.87
累计净值	0.58	2.64	1.78	4.23

数据来源：东北证券

表 19: EP_Q_5Y 中证 500 选股结果

	累计收益		第 10 组 超额收益	多空收益 (10-1)
	第 1 组	第 10 组		
胜率	53.76%	56.99%	65.59%	79.57%
年化收益率	-4.51%	13.90%	7.55%	17.80%
年化波动率	33.03%	30.59%	4.51%	7.57%
Sharpe	-0.14	0.45	1.67	2.35
最大回撤	59.65%	41.71%	3.77%	3.92%
最大回撤起始	2010/3/31	2011/2/28	2012/1/31	2016/1/31
最大回撤结束	2012/11/30	2012/11/30	2012/11/30	2016/2/29
收益回撤比	-0.08	0.33	2	4.54
平均盈利	6.72%	7.24%	1.31%	2.11%
平均亏损	7.64%	6.14%	0.71%	1.35%
盈亏比	0.88	1.18	1.86	1.56

累计净值	0.7	2.75	1.76	3.57
------	-----	------	------	------

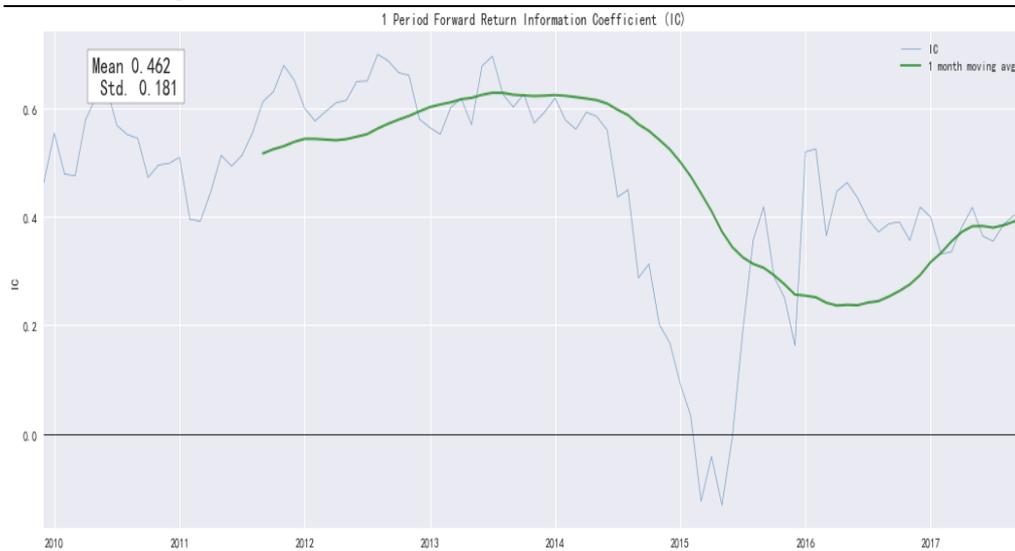
数据来源：东北证券

2.4.3. EP 分位数因子与 EP 因子和反转因子的相关性

下面，我们以过去 3 年 EP 分位数因子为例，进一步研究其与 EP 因子与反转因子之间的关系。

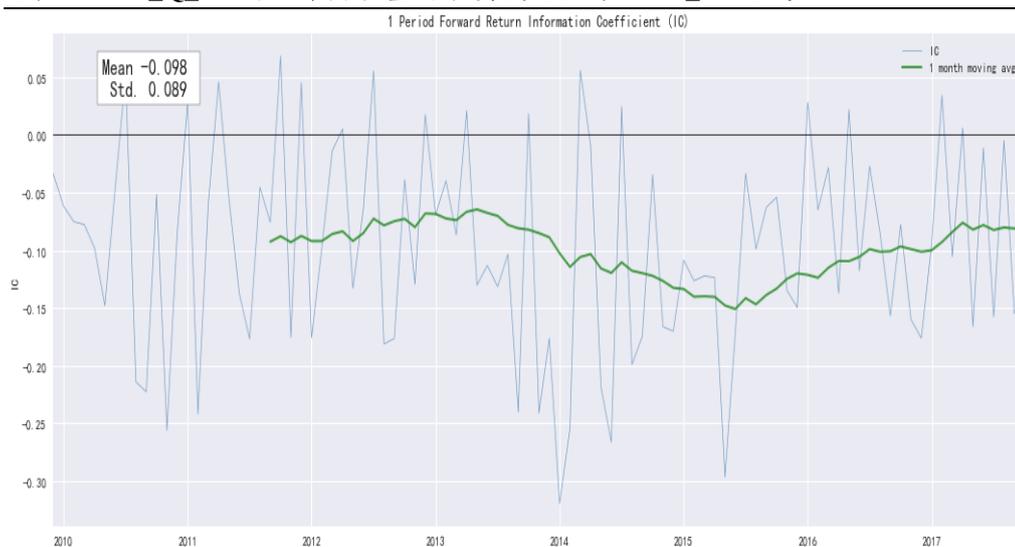
从中我们可以发现，EP_Q_3Y 这个因子与 EP 自身有较强的相关性。但与反转因子（一个月动量，三个月动量，三年动量，过去 3 年复权价格分位数）相关性都不高。经过检验，EP_Q_3Y 对 EP 和任意一个反转因子进行回归的残差都具有显著性。

图 35: EP_Q_3Y 与 EP 因子横截面上的 Rank_IC 曲线



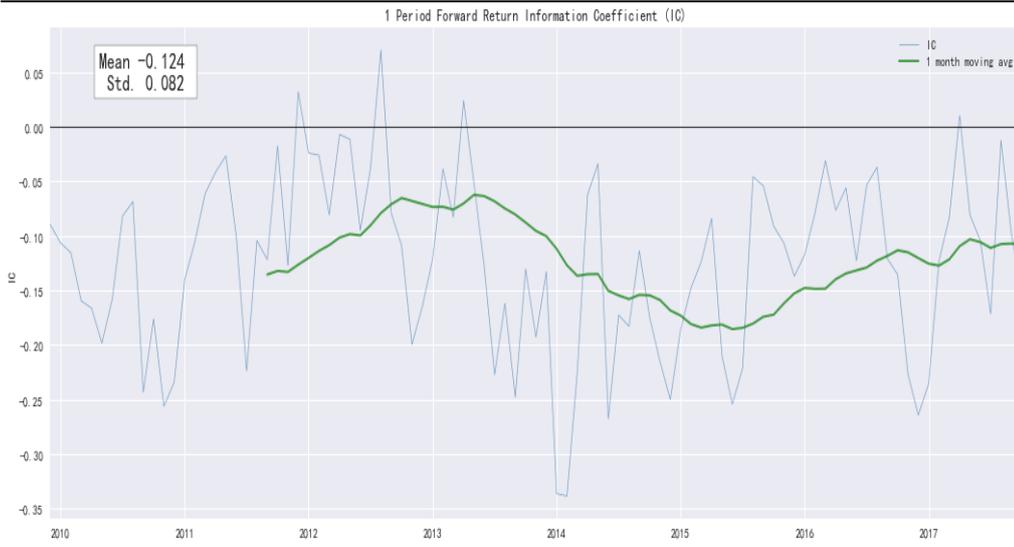
数据来源：东北证券，Wind

图 36: EP_Q_3Y 与一个月动量因子横截面上的 Rank_IC 曲线



数据来源：东北证券，Wind

图 37: EP_Q_3Y 与三个月动量因子横截面上的 Rank_IC 曲线



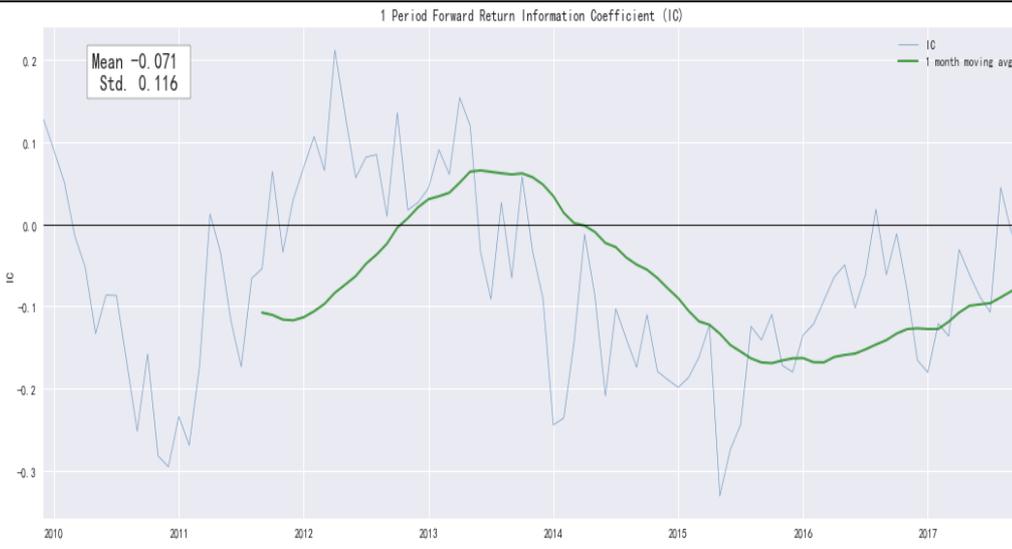
数据来源：东北证券，Wind

图 38: EP_Q_3Y 与三年动量因子横截面上的 Rank_IC 曲线



数据来源：东北证券，Wind

图 39: EP_Q_3Y 与过去 3 年复权价格分位数因子横截面上的 Rank_IC 曲线



数据来源: 东北证券, Wind

3. 其他研究

3.1. 风格轮动

3.1.1. 理论介绍

本节的理论出发点是 Fama-French 3 (下文简称为 FF3) 因子收益和风格收益既具有自相关性, 两者之间又有解释和被解释的关系, 通过之前一段时间 FF3 因子滞后项与当期风格收益之间的分类关系, 对当前 FF3 因子收益水平下对应的下一个周期以较高概率表现好的风格。以逻辑关系, 而非线性关系, 以相对概率, 而非绝对值的角度进行了风格轮动的探究。

在不进行周期和回测窗口优化的情况下, 使用单周数据做风格轮动的判断在回测期能够在收益和波动等评估指标下均表现比较优异。同时我们也展示了 1 周到 4 周的历史表现情况, 发现在 2014 年之前, 使用 3 或 4 周的周期频率在净值表现上较好, 而 2014 年之后轮动周期开始缩短, 净值斜率显示单周轮动判断收益更高。

本文方法下的风格判断, 既可以使用风格指数, 例如巨潮小盘价值、小盘成长、中盘价值、中盘成长、大盘价值和成长等, 也可以使用股票指数, 例如沪深 300、中证 500 和中证 1000 分别表示大中小盘风格, 结果均较为乐观, 可以作为市场风格判断依据。

3.1.2. 建模方法和结果

风格轮动是非常丰富的动态策略体系, 动量和反转效应也包含其中。通常来说, 我们希望根据对不同风格的收益率差异的判断来组建动态调整配置权重的策略, 在分析了动量和反转之后, 我们希望能够有相对提前的风格判别方法, 因此我们使用了 Logit 回归方法, 以滞后一期的 FF3 因子为自变量, 以当期小盘收益大于大盘收益, 价值收益大于成长收益的(0,1)逻辑关系作为因变量, 历史 60 周数据做 logistic 回归的参数拟合, 并根据当前的 FF3 因子水平对下一个周期的市场风格进行判断, 即通过以下公式计算当前拟合的参数以及 FF3 因子数值对应下一周期风格概率

$$p_1 = P\{Small > Large | x_t\} = \frac{1}{1 + \exp\{-a_1 x_t\}} \quad (3.1)$$

$$p_2 = P\{Value > Growth | x_t\} = \frac{1}{1 + \exp\{-a_2 x_t\}} \quad (3.2)$$

判别标准为

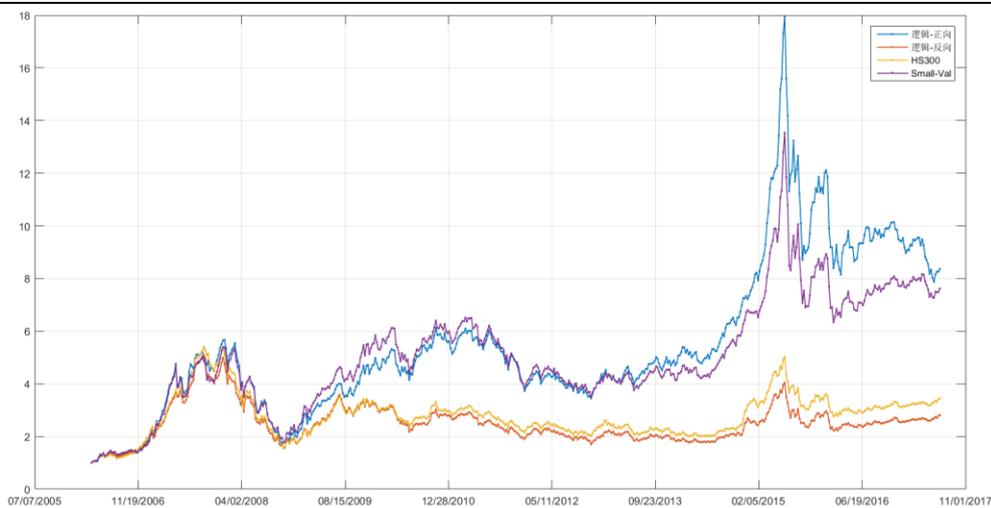
$$p_1 = \begin{cases} > 0.55 & Small - Cap \\ [0.45, 0.55] & Mid - Cap \\ < 0.45 & Large - Cap \end{cases} \quad (3.3)$$

$$p_2 = \begin{cases} > 0.5 & Value \\ \leq 0.5 & Growth \end{cases} \quad (3.4)$$

无可否认，小盘价值作为 6 个风格指数中收益最高的指数，与其他策略比较起来有一部分时间表现是十分优异的，并且在所有风格指数都回撤较明显时 Logit 策略也有较大的回撤和波动，但是无论在收益上还是风险上，Logit 做出的选择已经有所进步，特别是表征下行风险回报的 Sortino 指数大幅领先于其他策略。近两年，通过 Logit 进行风格预判，在风格变化加速的情况下开始表现抢眼，尤其是在 15 年开始逐渐拉开了与其他策略间的差距，股灾之后一骑绝尘。

本文细节可参考《东北金工：风格轮动初探》。

图 40：不同策略净值表现



数据来源：东北证券，Wind

3.2. 人工智能

2017 年，人工智能研究方兴未艾，以围棋为突破点，取得世界瞩目的成果。继 AlphaGo 战胜李世石，之后又有 Master 以 60 连胜的记录横扫中日韩的围棋高手之后，2017 年 5 月份 AlphaGo 又 3 比 0 战胜了柯洁，Nature 重磅论文详细介绍谷歌 DeepMind 团队最新研究成果—AlphaGo Zero，在没有人类先验知识前提下，通过机器自主学习，达到超人境界。

今年以来，我们尝试将人工智能应用到量化投资领域，推出人工智能系列研究，发表人工智能系列报告的第一篇，围绕人工智能的发展历史，人工智能主要算法以及人工智能在金融领域的应用展开综合介绍，力求先为投资者勾勒出一幅人工智能全景图，后续我们将推出人工智能系列实战篇，结合多种机器学习算法，构造量化选股框架，为广大投资者提供成熟有效的策略。

3.2.1. 人工智能发展历史

我们认为人工智能发展至今，可以分为 5 个阶段，分别是人工智能的形成阶段，发展的黄金阶段，第一次发展低谷及复苏、第二次发展低谷，以及目前由深度学习引领的第五个发展阶段——现代人工智能。

人工智能 (Artificial Intelligence, AI) 的形成阶段，是从 1956 年到 1961 年。人工智能概念的正式确立是在 1956 年达特茅斯学院的一次学术会议上，参会人员希望将人工智能作为一门独立科学，确立其任务和发展路径。与会者们宣称，人工智能的特征都可以被精准逻辑运算描述，精准描述后就可以用机器来模拟和实现。会议相关的摩尔(Trenchard More)、麦卡锡 (John McCarthy)、明斯基 (Marvin Minsky)、塞弗里奇 (Oliver Selfridge)、所罗门诺夫 (Solomonoff) 作为 AI 领域的开创者，日后数十年间成为了 AI 领域研究的领军人物，此次会议第一次正式使用人工智能这一术语，其中参会的两人塞弗里奇(Oliver Selfridge)和纽厄尔 (Allen Newell)，塞弗里奇发表了一篇模式识别的文章，而纽厄尔探讨计算机模拟人类下棋，他们分别代表两派观点。讨论会的主持人，神经网络鼻祖之一的皮茨(Pitts)最后总结时说：“(一派)人企图模拟神经系统，而纽厄尔则企图模拟心智(Mind).....但殊途同归。”皮茨预示了人工智能随后几十年按照符号计算和神经网络的两个路径发展。

在达特茅斯会议之后的数十年间，人工智能迎来了高速发展，计算机解决了一些数学证明以及学习使用英语等问题，AI 的快速发展使得研究人员乐观情绪高涨，认为具备人类思考能力的机器在不久的将来就会出现，与此同时，国防机构也对 AI 充满浓厚兴趣，对这一领域投入大量资金，希望获得军事上的领先。在这一时期研究成果呈井喷态势涌现。

第一次低谷及复苏是发生在 1974 年到 1986 年。第一次低谷的到来有必然的原因，其实在黄金十年期间人工智能的理论基础和技术发展并没有获得实质性突破，人工智能技术经历了从 1956 年开始的将近 20 年的高速发展之后，终于遇到了自己的瓶颈，于 1974 年迎来了第一次低谷期。人工智能在第三个阶段陷入低谷主要还是因为整个学科理论基础和技术实现都存在很大短板，遭遇危机是必然的，可以分三个方面来解释。第一，随着程序计算复杂性上升，计算机性能满足不了学者提出的研究需求。第二，没有大容量数据库支持，研究面临数据缺失的困境，无法找到足够数据量支撑机器学习算法的训练。第三，就像明斯基所说，作为人工智能基础的数学理论还不够完善。上述三个原因都从另一方面反映了人工智能的发展，不仅是本身学科的发展，也需要依赖于其他领域的同步发展，比如计算机硬件、基础数学和数据科学。然而这一次的“低谷”仅仅持续了不到七年时间便迎来了又一个七年的复苏。推动此次复苏的标志性事件有两个，一个是 80 年代初的专家系统，另外一个则是第五代计算机的研究热潮。

1987 年人工智能的发展陷入第二次低谷。主要原因有两个，一是个人计算机的出现

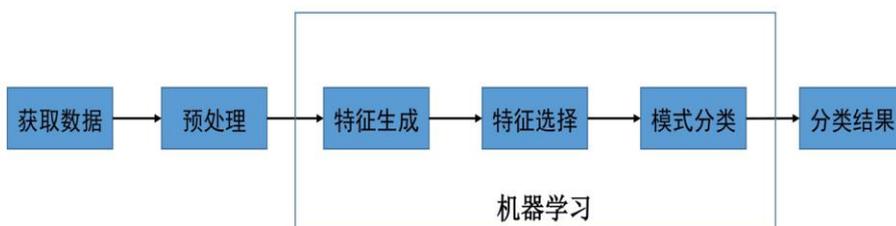
冲击了专家系统，二是“人工智能计算机”研发的失败。当时苹果、IBM 开发的第一代个人计算机开始走向社会，价格低廉，迅速挤占了专家系统的市场，导致专家系统的需求急剧下滑。第二个是，被寄予厚望的第五代计算机“人工智能计算机”，在人机交互的关键技术没能实现突破。导致政府对于人工智能支持经费又进一步削减。在削减了大量经费之后，人工智能研究在此期间一度进入停滞期。我们认为，第四阶段，也就是人工智能的第二次发展低谷，表面上看是专家系统失去市场和第五代计算机的研发失败，但是实际上结合人工智能发展的轨迹和当时社会环境来看，我们认为原因实质上不仅仅这样，其实是有两个更深层的原因。首先，人工智能学科研究过于单一，尤其前期符号计算垄断了整个学科，没有其他研究方向来分担风险；其次，人工智能的研究资金大部分是来自于政府机构，没有在社会上形成健全的产业链，一旦政府研究热点发生转移，就会出现经费不足的情况。

3.2.2. 人工智能算法

1950 年初期，人工智能追求研发能够像人类一样具有智力的机器，研究界把这个称之为“强人工智能”，后续出现了专家系统，在特定领域运用人工智能技术，给人工智能发展注入新的活力，然而又带来了难以移植，成本昂贵等问题。1980 年之后机器学习成为 AI 研究的主流，研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构使之不断改善自身的性能。2000 年左右，计算机科学家在神经网络研究基础上加入多层感知器构建深度学习模型，成功解决了图像识别、语音识别以及自然语言处理等领域的众多问题。近年来，在 IBM 等科技巨头推动下认知计算（Cognitive computing）蓬勃发展，通过学习理解语言、图像、视频等非结构化数据，更好地从海量复杂数据中获得知识，做出更为精准的决策。

机器学习是人工智能领域研究的核心问题之一，理论成果已经应用到人工智能的各个领域，机器学习算法通过模式识别系统根据事物特征将其划分到不同类别，通过对识别算法的选择和优化，使其具有更强的分类能力。机器学习模式识别流程，包括获取数据、数据预处理、特征生成、特征选择、模式分类、和最后生成分类结果等步骤。

图 41：机器学习模式识别流程



数据来源：东北证券

这部分主要介绍人工智能领域比较著名的 4 个算法，分别是感知器、决策树，支持向量机和深度学习中比较著名的算法——卷积神经网络。

感知器：美国计算机科学院罗森布拉特（F.Roseblatt）于1957年提出感知器，是神经网络第一个里程碑算法。所谓感知器，是一种用于二分类的线性分类模型，其输入为样本的特征向量，计算这些输入的线性组合，如果输出结果大于某个阈值就输出1，否则输出-1。作为一个线性分类器，感知器有能力解决线性分类问题，也可用于基于模式分类的学习控制中。

聚类算法：从机器学习的角度，聚类算法是一种“无监督学习”，训练样本的标记信息是未知的，根据数据的相似性和距离来划分，聚类的数目和结构没有事先给定。聚类的目的是寻找数据簇中潜在的分组结构和关联关系，通过聚类使得同一个簇内的数据对象的相似性尽可能大，同时不在同一个簇中的数据对象的差异性也尽可能地大。在人工智能中，聚类分析亦被称为“无先验学习”，是机器学习中的重要算法，目前被广泛应用于各种自然科学和工程领域，如心理学、生物学、医学等。目前已经提出多种聚类算法，可分为：划分方法、层次方法、基于密度的方法、基于网格的方法和基于模型的方法。其中著名的分类算法k-means算法就是基于划分的聚类算法。

决策树：决策树是一种简单却使用广泛的分类器，**通过训练数建立决策树对未知数据进行高效分类**。一棵决策树一般包括根结点、内部结点和叶子结点；叶子结点对应最终决策结果，每一次划分过程遍历所有划分属性找到最好分割方式。决策树的目标是将数据按照对应的类属性进行分类，通过特征属性的选择将不同类别数据集合贴上对应的类别标签，使分类后的数据集纯度最高，而且能够通过选择合适的特征尽量使分类速度最快，减少决策树深度。

决策树生成过程一般分为三个步骤：

- ✓ **特征选择：**是指从训练数据中众多的特征中选择一个特征作为当前节点的分裂标准。如何选择特征有着很多不同量化评估标准，从而衍生出不同的决策树算法。
- ✓ **决策树生成：**根据选择的特征评估标准，从上至下递归地生成子节点，直到数据集不可分则停止决策树生长。
- ✓ **剪枝：**决策树容易过拟合，一般来需要剪枝，缩小树结构规模、缓解过拟合。剪枝技术有预剪枝和后剪枝两种。

支持向量机：支持向量机SVM（Support Vector Machine）是由Cortes和Vapnik于1995年首先提出的，它是一种基于统计学习的机器学习方法，在小样本分类上也能获得良好统计规律。同时由于在文本分类中表现出特有的优势，成为当时机器学习领域研究的热点。SVM的学习方法主要包括：线性可分向量机、线性支持向量机以及非线性支持向量机。SVM主要思想是，建立一个最优决策超平面，使得该平面两侧距平面最近的两类样本之间的距离最大化，从而对分类问题提供良好的泛化能力。将复杂的模式分类问题非线性投射到更高维空间变成线性可分的，因此支持向量机算法在特征空间建立分类平面，可解决非线性可分的问题，其学习策略是间隔最大化，将分类问题转化为一个凸二次规划问题的求解。SVM采用核函数技巧将原始特征映射到更高维空间，解决原始低维空间线性不可分的问题。

卷积神经网络：当人工智能领域在20世纪50年代起步的时候，生物学家开始提出简单的数学理论，来解释智力和学习的能力如何产生于大脑神经元之间的信号传

递。当时的核心思想一直保留到现在，如果这些细胞之间频繁通信，神经元之间的联系将得到加强。神经学研究表明，人类大脑在接收到外部信号时，不是直接对数据进行处理，而是通过一个多层的网络模型来获取数据的规律。这种层次结构的感知系统使视觉系统需要处理的数据量大大减少，并保留了物体有用的结构信息。由于这些信息的结构一般都很复杂，因此构造深度的机器学习算法去实现一些人类的认知活动是很有必要的。这里主要介绍一个经典的深度学习算法：卷积神经网络（CNNs）。卷积神经网络（CNN）是近年发展起来，并引起广泛重视的一种高效识别方法。受生物自然视觉认知机制启发而来。1959年，休博尔（Hubel）等人发现，动物视觉皮层细胞负责检测光学信号。受此启发，1980年福岛邦彦（Kunihiko Fukushima）提出了CNN的前身—神经认知机（neocognitron）。20世纪90年代，燕乐纯（LeCun et al.）等人发表论文，设计了一种多层的人工神经网络，取名叫做LeNet-5，可以对手写数字做分类，LeNet-5确立了CNN的现代结构，在每一个采样层前加入卷积层。在图像识别领域，CNNs已经成为一种高效的识别方法。

3.2.3. 人工智能在金融投资领域应用

据高盛统计，人工智能为美国金融业每年节约和新增收入340-430亿美元。但是，我们认为目前人工智能在国内金融领域的应用还处于探索阶段，应用场景还是集中在和大数据分析、与互联网连接紧密的领域，分别列举大数据基金、人工智能预测和智能投顾三个例子来进行阐述。

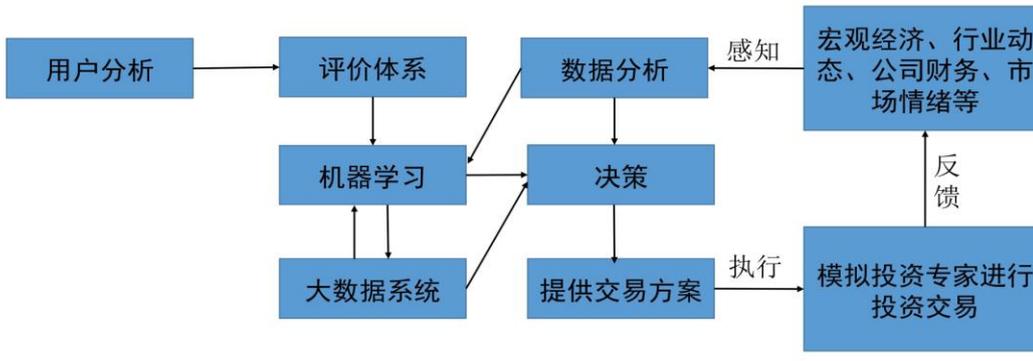
1、**大数据基金**。2012年5月，世界首家基于社交媒体的对冲基金 Derwent Capital Markets 在屡次跳票后终于上线，它会即时关注 Twitter 中的公众情绪，通过大规模文本数据分析，来指导投资。其实早在上世纪80年代，就诞生了所谓媒体指标，通过收集电视广播和纸质媒体上关于经济和股市的看法，用算法拟合公众情绪，然后作为市场操作中的重要参考指标。事实上，大数据基金是一个相对简单的应用，通过构建大数据因子，来反应市场或者单个股票特性对市场上的波动做出及时反应。从目前大数据指因子的编制方法上看，可分为情绪类、行业类和专家类。其中，情绪类大数据因子适用于市场情绪高涨的牛市；行业大数据因子适用于侧重研究公司基本面的投资者；而专家类因子相当于跟随专业投资者进行调仓操作，但是会存在专家对市场误判的风险。大数据基金产品，目前国内市场上主要有淘宝大数据100，百发100指数，雪球智选大数据100等。

2、**运用人工智能进行预测**。这属于比较前沿的领域，主要列举两个国外成功的例子。第一个例子是，瑞贝林基金，它是全球第一个纯人工智能驱动型基金，曾成功预测了2008年全球股市的动荡，并在2009年给希腊债券信用评级是F，比惠誉调低评级还提前了一个月。第二个例子是日本三菱公司发明的智能机器算法，每月10号预测日本股市在30天后是上涨还是下跌。经过四年左右的测试，模型的正确率高达68%。目前国内这方面的研究和实践已经有了一点基础，这几年有不少卖方研究在关注这一领域，但真正可以用于实盘交易的策略还不多见。现在有不少开放平台比如优矿、米筐、聚宽等，可以帮助投资者在线进行简单策略实现，也包括在线回溯机器学习算法。

3、**智能投顾**。智能投顾一大功能是为用户画像，结合个人客户的风险偏好和理财目标、结合宏观经济、行业动态和公司财务等指标，通过大数据分析，用智能算法模拟投资专家为客户推荐合适的资管方案。智能投顾的运行，一般包括用户画像、

大数据分析、机器决策、交易执行等部分。各举一个国内和国外的例子，国内的例子是芝麻信用，用淘宝消费记录和余额宝投资数据为用户刻画出真实立体的信用画像，结合蚂蚁聚宝这些理财平台给用户合适的理财产品。国外的例子是，2014年成立的日本企业艾帕卡，利用深度学习进行图像识别，通过卫星遥感图像实时分析一国经济运行状况，比如港口的吞吐量，农作物种植面积，在建工程数量等，根据这些信息辅助用户进行投资决策。

图 42: 智能投顾运行模式



数据来源：东北证券

总的来看，人工智能从诞生伊始就成为研究热点，发展过程中又不断遭受质疑，一直在曲折中前进，未来人工智能在金融领域的应用具有极大的发展潜力。

本文细节可参考《人工智能系列报告综述篇：人工智能发展史及算法介绍》。

3.3. 机构交易行为视角下的行业轮动

3.3.1. 理论基础

研究 A 股市场上的资金流量，利用股票超大单资金数据研究机构交易行为中的行业偏好，验证机构投资者主动净买入指标的有效性，并根据指标，构建中信一级行业轮动配置组合，采用分组回测方法，检验策略收益风险情况。

如何能够通过有效指标衡量机构行为是研究重点。买卖方向与资金量往往是反映机构交易意愿强弱的有效指标，通过构建机构投资者主动净买入指标来衡量机构投资者的交易行为，指标构建分为三个步骤：投资者分类、个股主动买入金额、行业主动净买入金额统计。

首先把股票日内订单按挂单金额大小分类为超大单、大单、中单、小单，并根据分类结果来划分机构、大户、中户、散户，具体数据如表 1 所示。

表 20: 成交单分类

	挂单金额分类	投资者分类
超大单	100 万元 < 挂单量	机构
大单	20 万元 < 挂单量 < 100 万元	大户
中单	4 万元 < 挂单量 < 20 万元	中户
小单	挂单量 < 4 万元	散户

数据来源：东北证券、Wind

根据主动去成交已经存在的对手单还是挂单等待成交，将成交单分为主动和被动；同时，根据投资者主动买入（*Mine_Capital*）和主动卖出（*Offer_Capital*）的差值数量来表示投资者交易意愿的方向和强弱，具体计算公式如下。

$$Net_Capital = Mine_Capital - Offer_Capital$$

因为市场日内信息噪音较多，而且不排除有短线交易者利用大单进行套利，所以我们采用周度数据，将主动超大单资金净流入金额按周度求和，可以衡量市场上机构投资者，将单个股资金净流入额映射到行业上，可以间接获得机构投资者在行业配置偏好。

$$industry_Net_Capital = \sum_{date=j}^{tradedays} \sum_{stock=i}^{stocks} Net_Capital$$

按照中信一级行业划分，根据上述公式计算行业超大单净主动买入额 *Industry_Net_Capital*，反映了某一行业中机构投资者的净买入量。机构净主动买入额越小，表明本期内机构投资者资金在这一行业净流出；相反，净主动买入额越大，则说明机构投资者资金在流入该行业。按照上述逻辑，我们运用净主动买入额指标来衡量机构投资者的行业偏好，构建行业轮动模型，获取超额收益。

3.3.2. 策略构建和结果

回测区间是 2013 年 1 月 1 日至 2017 年 8 月 1 日，利用 A 股市场所有股票超大单主动净买入金额（大于 100 万）数据，根据股票所属行业，构建中信一级行业机构主动净买入指标。

采用分组回测方法检验机构主动净买入指标有效性。为保证数据的可靠性，对机构主动净买入额数据进行标准化和去极值处理。去极值过程是将截面上 97.5 分位数以上和 2.5 分位数以下的数值，分别用 97.5 分位数和 2.5 分位数数据代替。采用 z-score 标准化方法，求截面数据（指标）的算术平均值（数学期望） μ 和标准差 δ ，z-score 标准化公式如下：

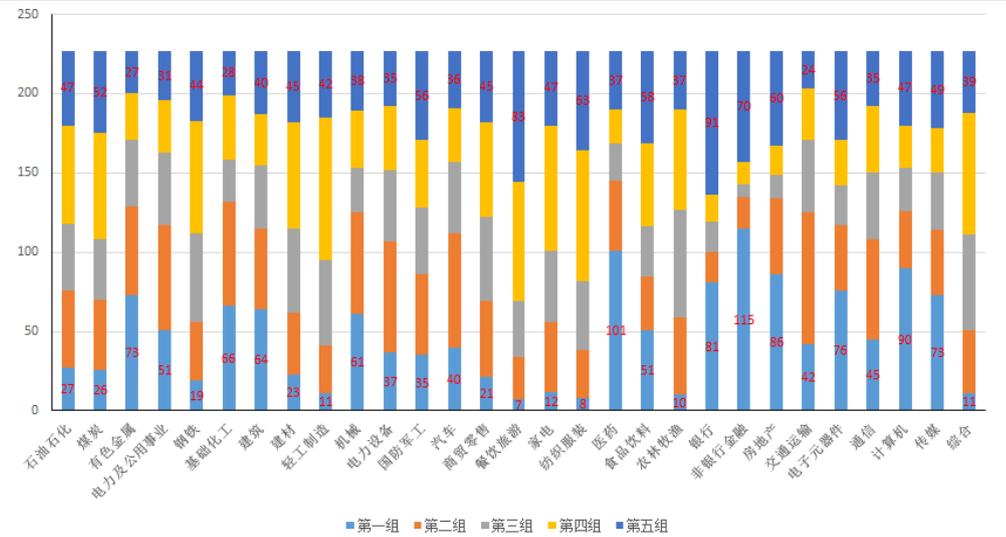
$$x_i = \frac{x_i - mean(x)}{\sigma(x)}$$

用标准化后的机构主动净买入金额 *Industry_Net_Capital* 将截面上的中信一级行业划分为 1-5 组进行分组回测，第 1 组主动净买入量最小，第 5 组主动净买入量最大，持仓 1 周、5 周、10 周。分组规则如下：

- 1、回测周期：2013 年 1 月 1 日至 2017 年 8 月 1 日
- 2、指标构建股票池：以中信一级行业为基准，运用行业内所有股票构建行业机构主动净买入量。
- 3、对时间序列上的行业截面，根据行业机构主动净买入量指标，将中信一级行业分为 5 组，分别位于指标的 0-20%，20-40%，40%-60%，60%-80%，80%-100%。
- 4、分别对第 1 组-第 5 组的构建多空组合，分别做多第 1-5 组，观察收益率情况；构建第 5 组与第 1 组的多空组合，观察收益情况。

将中信 29 个行业按机构主动净买入金额分组，统计行业在各组中出现次数，银行与非银金融出现在第 5 组与第 1 组次数较多，呈现两端大中间小特点，

图 43: 中信一级行业分布图



数据来源: 东北证券

计算不同分组和持仓周期的平均收益率，可以看出第 1 组，即机构主动买入量最小的一组，回测期内预测 1、5、10 周之后的收益率平均值均为负值，第 5 组各持仓周期的平均收益均为正值；考虑持仓期限的不同，第 5 组持仓 1 周的收益率和持仓 10 周相比更改，可以推断机构主动净买入指标是一个短期指标，我们在下文会继续实证检验。

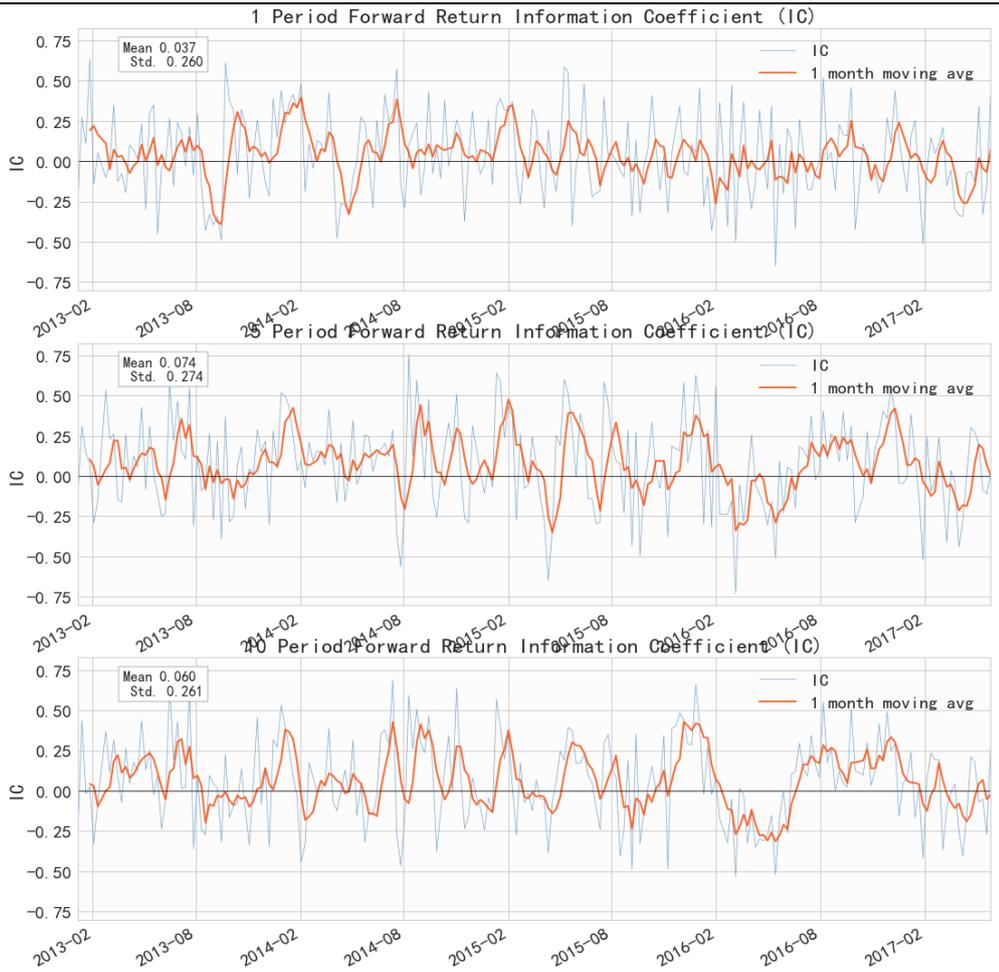
图 44: Industry_Net_Capital 分组平均收益



数据来源: 东北证券

计算机构主动净买入指标预测 1、5、10 周收益率的 IC 值（信息系数）。IC 值是采用 Spearman 相关系数计算，计算某时点某因子在全部股票因子暴露值排名与其下期收益率排名的截面相关系数，IC 值能够很好地反映因子的预测能力。IC 越高，就表明该因子在该期对股票收益的预测能力越强。本文计算 Industry_Net_Capital 指标 1、5、10 周的 IC 值，取月度平均值，发现多数月份 IC 值为正，表明机构净买入量指标和下期收益率有正相关性。

图 45: Industry_Net_Capital 1、5、10 周 IC 值序列



数据来源：东北证券

一般认为 IC 的绝对值大于 3%，指标的预测能力较强。可以看出，3 种持仓周期下的 IC 均值都大于 0，IC 具有较高的标准差，IC 大于 0 的比例均大于 50%，显示机构主动净买入指标和未来收益呈正相关性，IR 值在 1 周、5 周、10 周分别达到了 14.2%、27.0%、23.0%，考虑到持仓期限的不同，计算年化 IR 分别达到 1.02、0.87、0.52，机构主动净买入指标在短期比长期预测能力更强。

表 21: Industry_Net_Capital 指标 1、5、10 周的 IC 值、IR 值

	1 周	5 周	10 周
IC 平均值	3.7%	7.4%	6.0%
IC 标准差	26.0%	27.4%	26.1%
IC > 0 的比例	54.6%	61.7%	59.0%
IC > 3% 的比例	49.8%	57.3%	54.2%
IR (IC 平均值/IC 标准差)	0.14	0.27	0.23
年化 IR	1.02	0.87	0.52

数据来源：东北证券、Wind

按照机构主动净买入指标将中信一级行业分为 5 组，第 5 组机构主动买入金额最多，第 1 组机构主动买入金额最少，5 组回测期内持仓 1 周的净值曲线如图所示，第 5

组净值回测期内收益远高于第 1 组，尤其在市场上涨行情中机构买入量多的行业上涨更明显，第 1 组回测收益与 Wind 全 A 相比，收益低于 Wind 全 A。

图 46: 1-5 组持仓 1 周净值与 Wind 全 A 净值走势比较



数据来源：东北证券

按照机构主动净买入指标将中信一级行业分为 5 组，每组做多持仓 1 周，第 1-5 组年化收益率呈现增长的趋势，各组年化标准差均在 30% 左右，夏普比率第 5 组达到 0.73，远高于第 1 组，在市场下跌中各组的最大回撤均接近 50%，无法规避市场风险，但是第 5 组最大回撤幅度最小，机构主动净买入指标在市场上涨行情中表现更好。

表 22: 不同分组持仓一周回测指标

	年化收益率	年化标准差	夏普比率	最大回撤
第一组	6.6%	29.2%	0.23	51.8%
第二组	16.0%	30.4%	0.53	50.1%
第三组	13.3%	31.0%	0.43	53.1%
第四组	16.4%	30.7%	0.53	53.7%
第五组	21.6%	29.5%	0.73	45.5%

数据来源：东北证券、Wind

构建多空组合，做多第 5 组，做空第 1 组，在整个回测期内多空组合收益稳步增长，多空组合持仓一周年化收益为 15.11%，年化标准差 13.84%，夏普比率 1.09，最大回撤 14.11%，在熊市和股灾期间回撤较小，由于牛市中存在行业普遍上涨的特征，多空组合由于空头的存在，在 2014 年 11 月- 2015 年 6 月期间涨幅小于沪深 300。

图 47: 多空组合净值曲线



数据来源：东北证券

表 23: 多空组合持仓一周回测指标

	年化收益率	年化标准差	夏普比率	最大回撤
多空组合收益指标	15.11%	13.84%	1.09	14.11%

数据来源：东北证券、Wind

4. 总结和展望

2017 年，我们在力求深度的前提下，继续扩展研究领域，覆盖 FOF、多因子、人工智能、以及行业轮动等多个方面。目前已经构建了完善的 FOF 体系，为不同风险偏好和收益目标的 FOF 投资系统提供适宜的解决方案；搭建多因子分析框架，探索特质波动率、择时因子等新型有效因子在择时选股中的应用，构建策略组合；详细梳理人工智能发展历史、主要算法，以及在金融投资中应用，为实证提供理论基础；从机构交易行为角度，利用超大单资金研究行业轮动，推荐有效的行业轮动组合。

展望：

在东北证券金融工程组成立一周年之际，我们翻过了 FOF 研究体系和择时体系的旧台历，开始了多因子相关探索的新时代。同时，我们对市场热点紧密跟踪，进行机器学习和机构行为相关研究。在未来一年，我们仍将持续健全多因子体系，从构建因子库、量化基本面研究，到人工智能因子筛选和股票筛选，最终建立完备的多因子选股体系，为市场的最重点需求提供服务 and 思路。与此同时，我们还将深耕人工智能投资策略研究、开拓行为金融领域探索，为新的因子开发开辟新大陆。

在未来一年，我们将继续保持扎实研究的品质，进一步提高研究效率，进一步提升研究质量，进一步开拓研究领域，戮力成为一流金融工程团队！

分析师简介:

王琦: 金融工程分析师, 英国帝国理工学院数学与金融硕士, 2016年加入东北证券研究所。

肖承志: 金融工程分析师, 同济大学应用数学硕士, 2016年加入东北证券研究所。

重要声明

本报告由东北证券股份有限公司(以下称“本公司”)制作并仅向本公司客户发布, 本公司不会因任何机构或个人接收到本报告而视其为本公司的当然客户。

本公司具有中国证监会核准的证券投资咨询业务资格。

本报告中的信息均来源于公开资料, 本公司对这些信息的准确性和完整性不作任何保证。报告中的内容和意见仅反映本公司于发布本报告当日的判断, 不保证所包含的内容和意见不发生变化。

本报告仅供参考, 并不构成对所述证券买卖的出价或征价。在任何情况下, 本报告中的信息或所表述的意见均不构成对任何人的证券买卖建议。本公司及其雇员不承诺投资者一定获利, 不与投资者分享投资收益, 在任何情况下, 我公司及其雇员对任何人使用本报告及其内容所引发的任何直接或间接损失概不负责。

本公司或其关联机构可能会持有本报告中涉及到的公司所发行的证券头寸并进行交易, 并在法律许可的情况下不进行披露; 可能为这些公司提供或争取提供投资银行业务、财务顾问等相关服务。

本报告版权归本公司所有。未经本公司书面许可, 任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的, 须在本公司允许的范围使用, 并注明本报告的发布人和发布日期, 提示使用本报告的风险。

若本公司客户(以下称“该客户”)向第三方发送本报告, 则由该客户独自为此发送行为负责。提醒通过此途径获得本报告的投资者注意, 本公司不对通过此种途径获得本报告所引起的任何损失承担任何责任。

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格, 并在中国证券业协会注册登记为证券分析师。本报告遵循合规、客观、专业、审慎的制作原则, 所采用数据、资料的来源合法合规, 文字阐述反映了作者的真实观点, 报告结论未受任何第三方的授意或影响, 特此声明。

投资评级说明

股票 投资 评级 说明	买入	未来6个月内, 股价涨幅超越市场基准15%以上。
	增持	未来6个月内, 股价涨幅超越市场基准5%至15%之间。
	中性	未来6个月内, 股价涨幅介于市场基准-5%至5%之间。
	减持	在未来6个月内, 股价涨幅落后市场基准5%至15%之间。
	卖出	未来6个月内, 股价涨幅落后市场基准15%以上。
行业 投资 评级 说明	优于大势	未来6个月内, 行业指数的收益超越市场平均收益。
	同步大势	未来6个月内, 行业指数的收益与市场平均收益持平。
	落后大势	未来6个月内, 行业指数的收益落后于市场平均收益。

东北证券股份有限公司
中国 吉林省长春市

生态大街6666号
 邮编: 130119
 电话: 4006000686
 传真: (0431)85680032
 网址: <http://www.nesc.cn>

中国 北京市西城区

锦什坊街28号
 恒奥中心D座
 邮编: 100033
 电话: (010)63210800
 传真: (010)63210867

中国 上海市浦东新区

杨高南路729号
 邮编: 200127
 电话: (021)20361009
 传真: (021)20361258

中国 深圳南山区

大冲商务中心1栋2号楼24D
 邮编: 518000

机构销售
华北地区

销售总监 李航
 电话: (010) 63210890
 手机: 185-1501-8255
 邮箱: lihang@nesc.cn

华东地区

销售总监 袁颖
 电话: (021) 20361100
 手机: 136-2169-3507
 邮箱: yuanying@nesc.cn

华南地区

销售总监 邱晓星
 电话: (0755) 33975865
 手机: 186-6457-9712
 邮箱: qiuxx@nesc.cn